

ĐẠI HỌC QUỐC GIA TP HCM
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

BÁO CÁO ĐỒ ÁN MÔN HỌC

Chủ đề: Facial Expression Recognition

Môn học: Nhận dạng mẫu

Sinh viên thực hiện:

22120134 - Hoàng Tiến Huy

23120195 - Lê Hà Thanh Chương

23120232 - Lê Thượng Đế

23120245 - Nguyễn Quang Duy

23120258 - Lưu Trọng Hiếu

23120260 - Văn Đình Hiếu

Giáo viên hướng dẫn:

PGS.TS. Lê Hoàng Thái

Thầy Nguyễn Thanh Tình



Mục lục

Danh mục các thuật ngữ	vi
Danh sách các ký hiệu và chữ viết tắt	xii
1 Mở đầu	1
1.1 Bối cảnh và động lực	1
1.2 Mục tiêu đề án	1
1.3 Phạm vi và đối tượng nghiên cứu	1
1.4 Cấu trúc báo cáo	1
2 Kiến thức nền tảng	3
2.1 Bài toán nhận dạng mẫu và bài toán FER	3
2.2 Biểu diễn dữ liệu và đặc trưng	3
2.2.1 Đặc trưng thủ công	4
2.2.2 Đặc trưng học sâu và mô hình ngôn ngữ - hình ảnh	4
2.3 Quy trình tổng quát của hệ thống nhận dạng	4
2.4 Tổng quát hóa chéo miền và bài toán zero-shot	5
2.5 Các chỉ số đánh giá	6
3 Nghiên cứu chương sách giáo trình	8
3.1 Thông tin chương sách được chọn	8
3.2 Bài toán và giả định trong chương sách	8
3.3 Cấu trúc tổng quát của hệ thống AFEA	9
3.4 Không gian bài toán của phân tích biểu cảm	9
3.5 Kỹ thuật và phương pháp cốt lõi	11
3.5.1 Hệ thống mã hóa hành động khuôn mặt FACS	11
3.5.2 Trích xuất đặc trưng hình học	11
3.5.3 Trích xuất đặc trưng ngoại hình	11
3.6 Quy trình hoạt động chi tiết	12
3.6.1 Tiền xử lý và thu thập khuôn mặt	12
3.6.2 Trích xuất đặc trưng	12

3.6.3	So khớp, phân loại hoặc nhận dạng	12
3.7	Phân tích đa phương thức và bộ dữ liệu	13
3.8	Các câu hỏi mở	13
3.9	Ưu điểm và hạn chế từ góc nhìn giáo trình	13
4	Nghiên cứu bài báo khoa học tiên tiến	15
4.1	Thông tin bài báo	15
4.2	Hệ thống dữ liệu thực nghiệm (Datasets)	15
4.3	Động lực nghiên cứu và ý tưởng đề xuất	16
4.4	Phát biểu bài toán và phạm vi nghiên cứu	17
4.5	Giải pháp đề xuất CAFE	18
4.5.1	Ý tưởng cốt lõi	18
4.5.2	Luồng dữ liệu qua hệ thống	19
4.5.3	Kiến trúc chi tiết và các công thức cốt lõi	20
4.5.4	Mục tiêu kỹ thuật và tóm lược quy trình vận hành	22
4.5.5	Phân tích cơ sở khoa học và tính hiệu quả của phương pháp	23
4.6	Thực nghiệm minh họa và đánh giá kết quả	24
4.6.1	Thiết lập thực nghiệm và các phương pháp so sánh	24
4.6.2	Chỉ số đo lường hiệu suất	25
4.6.3	Kết quả thực nghiệm và phân tích chuyên sâu	25
4.7	Liên hệ với chương sách giáo trình nền tảng	26
4.7.1	Sự kế thừa từ lý thuyết nền tảng	26
4.7.2	Sự mở rộng và giải quyết các câu hỏi mở	27
4.7.3	Sự thay thế bởi hướng tiếp cận học sâu hiện đại	27
4.7.4	Phân tích đối sánh các đặc tính kỹ thuật	28
4.8	Đánh giá và nhận định	30
4.8.1	Phân tích các điểm mạnh về mặt kỹ thuật	30
4.8.2	Các giả định nền tảng và những giới hạn chưa được giải quyết	31
4.8.3	Góc nhìn cá nhân về tính thực tiễn và hiệu quả	32
4.8.4	Đề xuất hướng cải tiến và ứng dụng mở rộng	33

5	Demo minh họa và thực nghiệm	36
5.1	Mục tiêu thực nghiệm	36
5.2	Phân tích kỹ thuật từ mã nguồn	36
5.3	Thiết lập thực nghiệm	39
5.4	Kết quả thực nghiệm	40
5.5	Phân tích sai khác và thảo luận	42
5.6	Mở rộng hoặc cải tiến	43
5.7	Demo minh họa	44
6	Đánh giá, phân công và kết luận	45
6.1	Đánh giá phương pháp	45
6.2	Hạn chế và vấn đề chưa giải quyết	46
6.3	Nhận định cá nhân và hướng phát triển	46
6.4	Kế hoạch và phân công nhiệm vụ	48
6.5	Kết luận	48
	Tài liệu tham khảo	50

Danh sách bảng

3	So sánh đặc tính kỹ thuật giữa hệ thống phân tích truyền thống và phương pháp CAFE hiện đại.	28
4	Thiết lập thực nghiệm	40
5	So sánh kết quả thực nghiệm với bài báo gốc	41
6	Kết quả đánh giá chéo miền và mở rộng	42
7	Phân công nhiệm vụ và tỷ lệ hoàn thành	48

Danh sách hình vẽ

1	Sơ đồ kiến trúc tổng thể của phương pháp CAFE với cơ chế học mặt nạ sigmoid và các mô-đun tối ưu hóa đa nhiệm (Trích từ Hình 2 trong [8]).	20
2	Phân phối mẫu CK+48 ở chế độ 7 lớp (gồm Neutral).	41
3	Phân phối mẫu CK+48 ở chế độ 6 lớp peak-only.	41
4	So sánh phân phối số lượng mẫu của bộ dữ liệu CK+48 ở hai chế độ đánh giá. . . .	41

Danh mục các thuật ngữ

Thuật ngữ tiếng Việt / Tiếng Anh	
Biểu cảm nguyên mẫu	Prototypic emotional expression
Bộ lọc xác suất	Probability filter
Bộ lấy mẫu cân bằng	Balanced sampler
Bộ mã hóa văn bản	Text encoder
Bộ thích ứng thời gian	Temporal adapter
Bộ tiêu chuẩn đánh giá tĩnh	Static benchmark
Cấu trúc mạng phần dư	Residual network
Chỉ số đo lường	Evaluation metric
Chuyển đổi đặc trưng	Feature projection
Cơ chế chú ý chéo	Cross-attention
Cơ chế phòng vệ	Defense mechanism
Cơ chế rớt kênh ngẫu nhiên	Random channel-dropping
Đặc trưng biểu cảm đã chọn lọc	Filtered expression feature
Đặc trưng biểu cảm thô	Raw expression feature
Đặc trưng hình học	Geometric feature
Đặc trưng học sâu	Learned feature
Đặc trưng khuôn mặt	Face feature
Đặc trưng ngoại hình	Appearance feature
Đặc trưng thủ công	Hand-crafted feature
Độ chính xác trung bình	Mean accuracy
Tiếp tục ở trang sau...	

Thuật ngữ tiếng Việt / Tiếng Anh (tiếp theo)

Độ chính xác tổng thể	Overall accuracy
Động lực học thời gian	Temporal dynamics
Đơn vị hành động cơ mặt	Action unit
Giao thức thực nghiệm	Experimental protocol
Gợi ý ngôn ngữ - hình ảnh	Vision-language prompt
Hàm kích hoạt sigmoid	Sigmoid activation function
Hàm mất mát đa dạng kênh	Channel-diverse loss
Hàm mất mát phân loại	Classification loss
Hàm mất mát phân tách	Separation loss
Hệ thống giám sát người lái xe	Driver monitoring system
Hệ thống phân tích biểu cảm khuôn mặt tự động	Automated facial expression analysis
Học bán giám sát	Semi-supervised learning
Học máy	Machine learning
Học phân phối nhân	Label distribution learning
Học quá khớp	Overfit / Overfitting
Học vẹt	Rote learning
Huấn luyện từ đầu	From scratch
Kênh đặc trưng	Feature channel
Khả năng tổng quát hóa	Generalizability / Generalization
Khả năng tổng quát hóa chéo miền	Cross-domain generalization

Tiếp tục ở trang sau...

Thuật ngữ tiếng Việt / Tiếng Anh (tiếp theo)

Khả năng tổng quát hóa zero-shot	Zero-shot generalization
Khối chuyển đổi có khả năng học	Learnable projection head
Kiến trúc nhánh kép	Dual-branch architecture
Lô nhỏ	Mini-batch
Luồng quang học	Optical flow
Lớp kết nối đầy đủ	Fully connected layer
Mạng giáo viên	Teacher network
Mạng học sinh	Student network
Mạng nơ-ron	Neural network
Mạng nơ-ron đa tầng	Multi-layer perceptron
Mạng nơ-ron tích chập	Convolutional neural network
Mạng xương sống	Backbone
Mạng xương sống tiền huấn luyện	Pre-trained backbone
Mất cân bằng dữ liệu	Data imbalance
Mặt nạ	Mask
Mặt nạ sigmoid	Sigmoid mask
Miền dữ liệu	Domain
Miền dữ liệu đích (Miền đích)	Target domain

Tiếp tục ở trang sau...

Thuật ngữ tiếng Việt / Tiếng Anh (tiếp theo)

Miền dữ liệu nguồn (Miền nguồn)	Source domain
Mô-đun phân tách kênh	Channel-separation module
Mô hình diện mạo chủ động	Active appearance model
Mô hình hóa dựa trên tác tử	Agent-based modeling
Mô hình ngôn ngữ - hình ảnh	Vision-language model
Nghiên cứu cắt bỏ	Ablation study
Nhãn giả	Pseudo-label
Nhãn nhiễu	Noisy labels
Nhãn thực tế	Ground truth
Nhận dạng cảm xúc khuôn mặt	Facial Expression Recognition
Nhận dạng cảm xúc khuôn mặt có khả năng tổng quát hóa	Generalizable Facial Expression Recognition
Nhận dạng cảm xúc khuôn mặt động	Dynamic facial expression recognition
Nhận dạng cảm xúc khuôn mặt tĩnh	Static facial expression recognition
Nhận dạng khuôn mặt	Face recognition
Nội dung thiên lệch phương Tây	Western-centric content
Phản hồi thấu cảm	Empathic expression
Phân phối nhãn	Label distribution
Phân tách kênh	Channel-separation

Tiếp tục ở trang sau...

Thuật ngữ tiếng Việt / Tiếng Anh (tiếp theo)

Phép toán gộp cực đại	Max pooling
Phép toán trung bình	Mean operation
Quá trình hiệu chỉnh	Calibration
Quy luật	Patterns
Siêu tham số	Hyperparameter
Sự đánh đổi	Trade-off
Sự khác biệt cá nhân	Individual differences
Sự khác biệt về miền dữ liệu	Domain gap
Sự không khớp chiều không gian đặc trưng	Feature dimension mismatch
Tập dữ liệu kiểm tra chưa từng thấy	Unseen test set
Thế giới thực	Real-world
Thích ứng miền	Domain adaptation
Thiên lệch văn hóa trong nhận dạng cảm xúc	Cross-cultural facial expression recognition bias
Thu thập khuôn mặt	Face acquisition
Tinh chỉnh	Fine-tune
Tổng quát hóa liền mạch	Generalize seamlessly
Trích xuất và biểu diễn dữ liệu khuôn mặt	Facial data extraction and representation
Triển khai thực tế	Real-world deployment

Tiếp tục ở trang sau...

Thuật ngữ tiếng Việt / Tiếng Anh (tiếp theo)**Trợ lý ảo**

Virtual human

Tương tác người - máy

Human-robot interaction

Xác suất phân loại (Hệ số xác suất)

Logit

Danh sách các ký hiệu và chữ viết tắt

Chữ viết tắt	
AAM	Mô hình diện mạo chủ động (Active Appearance Model)
AFEA	Hệ thống phân tích biểu cảm khuôn mặt tự động (Automated Facial Expression Analysis)
API	Giao diện lập trình ứng dụng (Application Programming Interface)
AU	Đơn vị hành động cơ mặt (Action Unit)
AUC	Diện tích dưới đường cong (Area Under the Curve)
CAFE	Phương pháp mô phỏng nhận thức con người cho nhận dạng cảm xúc khuôn mặt (Cognition of humAn for Facial Expression)
CLIP	Mô hình tiền huấn luyện ngôn ngữ và hình ảnh đối lập (Contrastive Language-Image Pre-training)
DFER	Nhận dạng cảm xúc khuôn mặt động (Dynamic Facial Expression Recognition)
DMS	Hệ thống giám sát người lái xe (Driver Monitoring System)
EAC	Phương pháp học nhất quán dựa trên xóa vùng ảnh (Erasure-based Consistency)
FACS	Hệ thống mã hóa hành động khuôn mặt (Facial Action Coding System)
FC	Lớp kết nối đầy đủ (Fully Connected)
FER	Nhận dạng cảm xúc khuôn mặt (Facial Expression Recognition)
FR	Nhận dạng khuôn mặt (Face Recognition)
GFER	Nhận dạng cảm xúc khuôn mặt có khả năng tổng quát hóa (Generalizable Facial Expression Recognition)

GRU	Khối nơ-ron có cổng (Gated Recurrent Unit)
HMM	Mô hình Markov ẩn (Hidden Markov Model)
HRI	Tương tác người - máy (Human-Robot Interaction)
LSTM	Mạng bộ nhớ dài - ngắn hạn (Long Short-Term Memory)
MA	Độ chính xác trung bình (Mean Accuracy)
MLR	Hồi quy logistic đa thức (Multinomial Logistic Regression)
OA	Độ chính xác tổng thể (Overall Accuracy)
OFER	Phương pháp nhận dạng biểu cảm khuôn mặt chịu lỗi (Occultation-aware FER)
RUL	Phương pháp học sự không chắc chắn (Relative Uncertainty Learning)
SCN	Mạng lọc nhiễu tự phục hồi (Self-Cure Network)
SOTA	Các phương pháp tiên tiến nhất (State-Of-The-Art)
SSL	Học bán giám sát (Semi-Supervised Learning)
SVM	Máy học vector hỗ trợ (Support Vector Machine)

Ký hiệu toán học

C	Số chiều của khối đặc trưng
c	Hằng số chuẩn hóa
D_{real}	Tập dữ liệu thực tế (miền dữ liệu đích)
D_{train}	Tập dữ liệu huấn luyện (miền dữ liệu nguồn)
F	Khối đặc trưng khuôn mặt tổng quát được trích xuất từ mô hình ngôn ngữ - hình ảnh lớn

$\tilde{F}$	Khối đặc trưng biểu cảm cuối cùng sau khi được chọn lọc qua mặt nạ
F^d	Ma trận các giá trị xác suất phân loại dự đoán
$\tilde{F}_{max}$	Ma trận chứa các giá trị cực đại trích xuất dọc theo chiều kênh
f	Ma trận đặc trưng biểu cảm thô trích xuất từ mạng học sâu khởi tạo mới
L	Số lượng các lớp cảm xúc cơ bản đầu ra
l_{cls}	Hàm mất mát phân loại
l_{div}	Hàm mất mát đa dạng kênh
l_{sep}	Hàm mất mát phân tách
l_{train}	Tổng hàm mất mát huấn luyện
M	Ma trận mặt nạ đặc trưng ban đầu
M_{drop}	Ma trận rớt kênh ngẫu nhiên
M_s	Ma trận mặt nạ sau khi đi qua hàm kích hoạt sigmoid
N	Số lượng mẫu ảnh trong một cấu trúc dữ liệu tính toán (ví dụ: kích thước batch)
$x_i, \tilde{x}_i$	Hình ảnh khuôn mặt đầu vào
y_i	Nhãn cảm xúc thực tế tương ứng
λ, β	Các siêu tham số cân bằng hàm mất mát

1 Mở đầu

1.1 Bối cảnh và động lực

Nhận dạng mẫu là một lĩnh vực nền tảng trong thị giác máy tính và trí tuệ nhân tạo, tập trung vào việc xây dựng các phương pháp giúp máy tính phát hiện, biểu diễn, phân loại hoặc xác minh đối tượng dựa trên dữ liệu quan sát được. Trong đồ án này, nhóm lựa chọn một chủ đề nhận dạng cụ thể để nghiên cứu theo hai hướng song song: nền tảng lý thuyết từ giáo trình và hướng tiếp cận hiện đại từ một bài báo khoa học tiên tiến.

1.2 Mục tiêu đồ án

Báo cáo hướng đến các mục tiêu chính sau:

- Trình bày có hệ thống kỹ thuật hoặc phương pháp cốt lõi trong chương sách đã chọn.
- Phân tích một bài báo SOTA có liên quan, bao gồm động lực, ý tưởng chính, phương pháp, thực nghiệm và thảo luận.
- Làm rõ mối liên hệ giữa kiến thức nền tảng trong giáo trình và hướng nghiên cứu hiện đại.
- Triển khai demo hoặc thực nghiệm minh họa, phân tích mã nguồn, thiết lập thực nghiệm và kết quả thu được.
- Đánh giá ưu điểm, hạn chế và đề xuất hướng mở rộng cho phương pháp được khảo sát.

1.3 Phạm vi và đối tượng nghiên cứu

Chủ đề nhận dạng được chọn: Facial Expression Recognition (Nhận dạng cảm xúc).

Chương sách giáo trình: Chương 19: Facial Expression Recognition - Handbook of Face Recognition 2nd Edition.

Bài báo SOTA: Generalizable Facial Expression Recognition.

1.4 Cấu trúc báo cáo

Phần còn lại của báo cáo được tổ chức như sau. Mục 2 trình bày kiến thức nền tảng cần thiết. Mục 3 tóm tắt và phân tích chương sách giáo trình. Mục 4 phân tích bài báo khoa học tiên tiến và so

sánh với nền tảng lý thuyết. Mục 5 trình bày phần thực hành, bao gồm demo, phân tích mã nguồn, thiết lập thực nghiệm và kết quả. Mục 6 đưa ra đánh giá, nhận định, phân công nhiệm vụ và kết luận.

2 Kiến thức nền tảng

Phần này trình bày các khái niệm cần thiết để người đọc có thể theo dõi chương sách giáo trình, bài báo SOTA và phần thực nghiệm. Nội dung được giới hạn trong phạm vi bài toán nhận dạng cảm xúc khuôn mặt (Facial Expression Recognition - FER), bao gồm cách phát biểu bài toán, cách biểu diễn dữ liệu và đặc trưng, quy trình tổng quát của một hệ thống nhận dạng, khái niệm tổng quát hóa chéo miền và các chỉ số đánh giá được sử dụng xuyên suốt báo cáo.

2.1 Bài toán nhận dạng mẫu và bài toán FER

Nhận dạng mẫu là quá trình ánh xạ một quan sát đầu vào sang một nhãn hoặc một quyết định dựa trên các quy luật học được từ dữ liệu. Một hệ thống nhận dạng mẫu điển hình bao gồm các bước chính: thu nhận dữ liệu, tiền xử lý, trích xuất đặc trưng, học mô hình, suy luận và đánh giá. Tùy mục tiêu, hệ thống có thể được thiết kế cho bài toán phân loại, xác minh, định danh hoặc phát hiện bất thường.

Nhận dạng cảm xúc khuôn mặt là một bài toán **phân loại** cụ thể trong nhận dạng mẫu. Đầu vào là một ảnh khuôn mặt x , đầu ra là một nhãn cảm xúc y thuộc một tập hữu hạn các lớp. Trong phạm vi báo cáo, bài toán được phát biểu trên hệ thống **bảy lớp cảm xúc cơ bản** ($L = 7$): ngạc nhiên (*surprise*), sợ hãi (*fear*), ghê tởm (*disgust*), hạnh phúc (*happy*), buồn bã (*sadness*), tức giận (*anger*) và trung tính (*neutral*). Hệ thống bảy cảm xúc này bắt nguồn từ lý thuyết tâm lý học về các biểu cảm nguyên mẫu mang tính phổ quát giữa các nền văn hóa, và được cả chương sách giáo trình lẫn bài báo SOTA sử dụng làm mục tiêu phân loại cốt lõi.

2.2 Biểu diễn dữ liệu và đặc trưng

Chất lượng của một hệ thống nhận dạng phụ thuộc lớn vào cách biểu diễn dữ liệu đầu vào thành đặc trưng phân biệt. Trong bài toán FER, có hai hướng biểu diễn chính, phản ánh đúng sự khác biệt giữa phương pháp truyền thống trong chương sách và phương pháp hiện đại trong bài báo SOTA.

2.2.1 Đặc trưng thủ công

Các hệ thống kinh điển dựa trên **đặc trưng thủ công** (hand-crafted feature), được thiết kế dựa trên tri thức chuyên gia về cấu trúc khuôn mặt. Hai nhóm chính bao gồm:

- **Đặc trưng hình học (geometric feature):** mô tả vị trí, hình dạng và khoảng cách giữa các điểm mốc trên khuôn mặt (khóe mắt, lông mày, miệng). Các điểm mốc này thường được định vị bằng mô hình diện mạo chủ động (Active Appearance Model - AAM).
- **Đặc trưng ngoại hình (appearance feature):** mô tả kết cấu da, nếp nhăn và sự thay đổi cường độ điểm ảnh khi cơ mặt co giãn, thường được trích xuất bằng bộ lọc tần số hoặc luồng quang học.

Ưu điểm của đặc trưng thủ công là dễ diễn giải và yêu cầu ít dữ liệu huấn luyện. Tuy nhiên, chúng nhạy cảm với sự thay đổi về ánh sáng, góc chụp và sự khác biệt cá nhân, dẫn đến khả năng tổng quát hóa kém trong điều kiện thực tế.

2.2.2 Đặc trưng học sâu và mô hình ngôn ngữ - hình ảnh

Các phương pháp hiện đại thay thế đặc trưng thủ công bằng **đặc trưng học sâu** (learned feature), được trích xuất tự động bởi mạng nơ-ron tích chập hoặc mạng biến áp thị giác. Đặc biệt, các **mô hình ngôn ngữ - hình ảnh** (vision-language model) như CLIP được tiền huấn luyện trên hàng triệu cặp ảnh - văn bản từ Internet, cho ra một không gian biểu diễn khuôn mặt có tính tổng quát rất cao. Đặc trưng từ những mô hình nền tảng này bao quát được nhiều điều kiện thu nhận và đặc điểm nhân dạng khác nhau, nên ít bị lệ thuộc vào phân phối của một tập dữ liệu cục bộ. Đây chính là nền tảng kỹ thuật mà phương pháp CAFE trong bài báo SOTA khai thác: thay vì học lại đặc trưng từ đầu, mô hình giữ cố định đặc trưng CLIP và chỉ học một mặt nạ để chọn lọc thông tin biểu cảm.

2.3 Quy trình tổng quát của hệ thống nhận dạng

Một hệ thống nhận dạng cảm xúc khuôn mặt tự động (Automated Facial Expression Analysis - AFEA) điển hình được mô tả bởi các thành phần sau:

- **Thu nhận và tiền xử lý:** phát hiện khuôn mặt, căn chỉnh theo điểm mốc, chuẩn hóa kích

thước và độ sáng, lọc nhiễu hoặc tăng cường dữ liệu (lật ngang, thêm nhiễu, xóa vùng ngẫu nhiên).

- **Trích xuất đặc trưng:** biến đổi ảnh khuôn mặt thô thành biểu diễn có khả năng phân biệt cao, bằng descriptor thủ công hoặc mạng học sâu.
- **Huấn luyện mô hình:** tối ưu tham số dựa trên tập dữ liệu và hàm mục tiêu (thường là hàm mất mát phân loại).
- **Suy luận:** dự đoán nhãn cảm xúc cho ảnh mới, kèm theo điểm tin cậy.
- **Đánh giá:** đo lường hiệu quả bằng các chỉ số phù hợp với bài toán phân loại.

Chương sách giáo trình đặc tả quy trình này thành ba bước cốt lõi: thu thập khuôn mặt, trích xuất và biểu diễn dữ liệu khuôn mặt, và nhận dạng cảm xúc. Phương pháp CAFE trong bài báo SOTA tuân thủ đúng khung ba bước này nhưng hiện đại hóa từng bước bằng công cụ học sâu.

2.4 Tổng quát hóa chéo miền và bài toán zero-shot

Một khái niệm trọng tâm của báo cáo là **khả năng tổng quát hóa chéo miền** (cross-domain generalization). Trong thực tế, mô hình thường được huấn luyện trên một **miền dữ liệu nguồn** (source domain) nhưng phải hoạt động trên các **miền dữ liệu đích** (target domain) có phân phối khác biệt về ánh sáng, độ phân giải, chủng tộc hay quy ước gán nhãn. Sự chênh lệch này được gọi là **khác biệt miền dữ liệu** (domain gap), và là nguyên nhân chính khiến độ chính xác suy giảm khi triển khai thực tế.

Cần phân biệt hai hướng tiếp cận:

- **Thích ứng miền (domain adaptation):** cho phép mô hình tiếp cận trước một số mẫu (có nhãn hoặc chưa) từ miền đích để tinh chỉnh. Hạn chế là điều kiện này thường bất khả thi khi phân phối miền đích không biết trước.
- **Tổng quát hóa zero-shot (zero-shot generalization):** mô hình chỉ được huấn luyện trên một miền nguồn duy nhất và phải suy luận trực tiếp trên các miền đích chưa từng thấy, tuyệt đối không tinh chỉnh. Đây chính là giao thức đánh giá mà bài báo SOTA và phần thực nghiệm của nhóm áp dụng.

Một rào cản kỹ thuật liên quan là hiện tượng **học quá khớp** (overfitting): mô hình ghi nhớ các đặc điểm nhiễu đặc thù của miền nguồn (nền ảnh, danh tính, điều kiện chụp) thay vì học các quy luật biểu cảm phổ quát, dẫn đến mất khả năng tổng quát hóa.

2.5 Các chỉ số đánh giá

Các bộ dữ liệu nhận diện biểu cảm khuôn mặt thường có phân bố lớp không đồng đều. Một số cảm xúc có số lượng mẫu lớn hơn đáng kể so với các cảm xúc còn lại. Vì vậy, nếu chỉ sử dụng độ chính xác tổng thể, kết quả có thể bị chi phối bởi các lớp phổ biến và chưa phản ánh đầy đủ khả năng nhận diện các lớp thiểu số. Báo cáo sử dụng bốn công cụ đánh giá sau:

- **Độ chính xác tổng thể (Overall Accuracy – OA):** là tỷ lệ số mẫu được dự đoán đúng trên tổng số mẫu kiểm thử:

$$OA = \frac{\sum_{c=1}^C TP_c}{N},$$

trong đó C là số lớp cảm xúc, TP_c là số mẫu thuộc lớp c được dự đoán đúng và N là tổng số mẫu kiểm thử. Chỉ số OA phản ánh hiệu năng chung của mô hình nhưng có thể cho kết quả cao ngay cả khi mô hình nhận diện kém các lớp ít mẫu.

- **Độ chính xác trung bình theo lớp (Mean Accuracy – MA):** là trung bình tỷ lệ dự đoán đúng của từng lớp:

$$MA = \frac{1}{C} \sum_{c=1}^C \frac{TP_c}{N_c},$$

trong đó N_c là tổng số mẫu thực tế của lớp c . Khác với OA, mỗi lớp đóng góp như nhau vào MA, bất kể số lượng mẫu của lớp đó. Vì vậy, chỉ số này phù hợp để đánh giá khả năng nhận diện đồng đều giữa các cảm xúc trong dữ liệu mất cân bằng.

- **Macro-F1:** là trung bình điểm F1 của tất cả các lớp:

$$\text{Macro-F1} = \frac{1}{C} \sum_{c=1}^C F1_c,$$

với

$$F1_c = \frac{2 \text{Precision}_c \text{Recall}_c}{\text{Precision}_c + \text{Recall}_c}.$$

Trong đó, Precision_c cho biết trong các mẫu được dự đoán là lớp c , có bao nhiêu mẫu thực sự thuộc lớp đó; Recall_c cho biết trong các mẫu thực tế thuộc lớp c , mô hình nhận diện đúng được bao nhiêu mẫu. Macro-F1 đánh giá đồng thời lỗi dự đoán nhầm và lỗi bỏ sót trên từng lớp.

- **Ma trận nhầm lẫn (Confusion Matrix):** biểu diễn số lượng mẫu của mỗi lớp thực tế được dự đoán vào từng lớp đầu ra. Các phần tử trên đường chéo thể hiện số mẫu được phân loại đúng, trong khi các phần tử ngoài đường chéo thể hiện các trường hợp nhầm lẫn. Ma trận này giúp xác định cụ thể những cặp cảm xúc mà mô hình khó phân biệt, chẳng hạn *fear* và *surprise*, hoặc *sadness* và *neutral*.

Trong báo cáo, OA được sử dụng để so sánh trực tiếp với kết quả được công bố trong bài báo gốc. MA và Macro-F1 được dùng để đánh giá mức độ cân bằng của mô hình giữa các lớp cảm xúc, còn ma trận nhầm lẫn được dùng để phân tích chi tiết các dạng lỗi dự đoán.

3 Nghiên cứu chương sách giáo trình

3.1 Thông tin chương sách được chọn

- **Tên sách:** *Handbook of Face Recognition*, 2nd Edition, do Stan Z. Li và Anil K. Jain chủ biên, Nhà xuất bản Springer, năm 2011 [4].
- **Tên chương:** Chương 19 - *Facial Expression Recognition*.
- **Tác giả chương:** Yingli Tian (The City College of New York), Takeo Kanade (Carnegie Mellon University) và Jeffrey F. Cohn (University of Pittsburgh).
- **Chủ đề chính:** Trình bày nền tảng và quy trình của một hệ thống phân tích biểu cảm khuôn mặt tự động (Automated Facial Expression Analysis - AFEA), bao gồm cấu trúc ba bước, không gian bài toán, các kỹ thuật trích xuất đặc trưng và nhận dạng biểu cảm.
- **Lý do lựa chọn:** Chương sách cung cấp khung lý thuyết kinh điển và toàn diện nhất về AFEA, định nghĩa rõ các thành phần, thuật ngữ và rào cản cốt lõi của lĩnh vực. Đây là hệ quy chiếu lý tưởng để đối sánh với bài báo SOTA hiện đại (phương pháp CAFE), qua đó làm rõ bước tiến hóa từ đặc trưng thủ công sang đặc trưng học sâu.

3.2 Bài toán và giả định trong chương sách

Chương sách định nghĩa **phân tích biểu cảm khuôn mặt** là các hệ thống máy tính cố gắng tự động phân tích và nhận dạng các chuyển động cơ mặt cùng sự thay đổi đặc trưng khuôn mặt từ thông tin thị giác. Các tác giả nhấn mạnh cần phân biệt giữa *phân tích biểu cảm* (facial expression analysis) và *phân tích cảm xúc* (emotion analysis): cảm xúc đòi hỏi tri thức ở mức cao hơn, vì một biểu cảm khuôn mặt ngoài việc truyền tải cảm xúc còn có thể thể hiện ý định, quá trình nhận thức, nỗ lực thể chất hoặc các thông điệp xã hội khác; việc diễn giải còn phụ thuộc vào ngữ cảnh, cử chỉ cơ thể, giọng nói, sự khác biệt cá nhân và yếu tố văn hóa. Do đó, hệ thống AFEA chỉ tập trung phân tích bản thân các hành động cơ mặt, bất chấp ngữ cảnh, văn hóa hay giới tính.

Về cấu trúc bài toán, đầu vào là ảnh tĩnh hoặc chuỗi video chứa khuôn mặt, đầu ra là các hành động cơ mặt (action unit) hoặc các biểu cảm cảm xúc nguyên mẫu. Chương sách nêu một số **giả định đơn giản hóa** phổ biến trong các hệ thống đương thời: phần lớn chỉ xử lý khuôn mặt ở góc

nhìn chính diện hoặc gần chính diện; nhiều hệ thống giả định khung hình đầu tiên của chuỗi là khuôn mặt chính diện và có biểu cảm trung tính để dùng làm ảnh tham chiếu; và thường giả định biểu cảm là đơn lẻ, bắt đầu và kết thúc ở trạng thái trung tính. Chương sách cũng chỉ rõ những giả định này thường không đúng trong thực tế, mở ra các hướng nghiên cứu nâng cao độ bền vững. Ứng dụng của AFEA rất rộng: giao tiếp phi ngôn ngữ và cận ngôn ngữ, tâm lý học lâm sàng, tâm thần học, thần kinh học, đánh giá mức độ đau, phát hiện nói dối, môi trường thông minh và giao diện người - máy đa phương thức.

3.3 Cấu trúc tổng quát của hệ thống AFEA

Theo chương sách, một hệ thống phân tích biểu cảm khuôn mặt tự động bao gồm ba bước cốt lõi:

1. **Thu thập khuôn mặt (Face acquisition):** Tự động xác định vùng khuôn mặt trong ảnh hoặc chuỗi video. Có thể dùng bộ phát hiện khuôn mặt cho từng khung hình, hoặc chỉ phát hiện ở khung đầu rồi theo vết ở các khung sau. Để xử lý chuyển động đầu lớn, có thể bổ sung bước phát hiện đầu, theo vết đầu và ước lượng tư thế.
2. **Trích xuất và biểu diễn dữ liệu khuôn mặt (Facial data extraction and representation):** Trích xuất các thay đổi do biểu cảm gây ra theo hai hướng chính là đặc trưng hình học và đặc trưng ngoại hình. Trước khi trích xuất, ảnh thường được căn chỉnh và chuẩn hóa nhằm loại bỏ ảnh hưởng của xoay trong mặt phẳng và khác biệt tỷ lệ.
3. **Nhận dạng biểu cảm khuôn mặt (Facial expression recognition):** Phân loại các thay đổi cơ mặt thành các đơn vị hành động cơ mặt hoặc các biểu cảm cảm xúc nguyên mẫu. Tùy việc có sử dụng thông tin thời gian hay không, phương pháp được chia thành dựa trên khung hình (frame-based) và dựa trên chuỗi (sequence-based).

3.4 Không gian bài toán của phân tích biểu cảm

Một đóng góp quan trọng của chương sách là phân tích **không gian bài toán** (problem space) gồm nhiều chiều khác nhau mà một hệ thống lý tưởng phải xử lý. Phần lớn nghiên cứu đương thời mới chỉ giới hạn trong một vùng hẹp của không gian này:

- **Mức độ mô tả:** Lựa chọn giữa nhận dạng một tập nhỏ các biểu cảm nguyên mẫu (ghê tởm,

sợ hãi, vui, ngạc nhiên, buồn, giận) và nhận dạng các đơn vị hành động cơ mặt tình vi theo hệ FACS.

- **Sự khác biệt cá nhân:** Hình dạng, kết cấu da, màu sắc, râu tóc thay đổi theo giới tính, chủng tộc và độ tuổi; kính mắt, trang sức có thể che khuất đặc trưng. Ngoài ra còn có khác biệt về độ biểu cảm giữa các cá nhân.
- **Sự chuyển tiếp giữa các biểu cảm:** Biểu cảm thực tế không đơn lẻ; các đơn vị hành động có thể xuất hiện theo tổ hợp cộng tính (additive) hoặc phi cộng tính (non-additive, hiệu ứng đồng phát âm).
- **Cường độ biểu cảm:** Hành động cơ mặt biến thiên về cường độ, được FACS đo bằng thang 3 hoặc 5 mức.
- **Biểu cảm chủ ý và tự phát:** Hai loại được điều khiển bởi hai đường vận động thần kinh khác nhau, khác biệt về thời gian và tính đối xứng, ảnh hưởng lớn đến các mô hình phụ thuộc thời gian như HMM.
- **Hướng đầu và độ phức tạp bối cảnh:** Xoay đầu ngoài mặt phẳng và sự xuất hiện của nhiều người, nền phức tạp đều làm khó việc phân tích.
- **Thu nhận ảnh và độ phân giải:** Ánh sáng, loại camera và độ phân giải ảnh hưởng tới kết quả; biểu cảm có thể nhận dạng được ở mức 48×64 điểm ảnh nhưng không nhận được ở 24×32 .
- **Độ tin cậy của nhãn thực tế:** Dữ liệu cần được gán nhãn thủ công và kiểm tra độ tin cậy liên quan sát viên, ưu tiên hệ số kappa thay vì tỷ lệ đồng thuận thô.
- **Bộ dữ liệu và quan hệ với các kênh hành vi khác:** Việc dùng các bộ dữ liệu nhỏ, đồng nhất khiến khả năng tổng quát hóa chưa được kiểm chứng; biểu cảm cũng chỉ là một trong nhiều kênh giao tiếp phi ngôn ngữ.

Chương sách tổng hợp các tiêu chí của một hệ thống AFEA lý tưởng theo bốn nhóm: tính bền vững (xử lý đa dạng đối tượng, ánh sáng, chuyển động đầu, che khuất, độ phân giải, mọi biểu cảm với cường độ và tính bất đối xứng khác nhau, biểu cảm tự phát), tính tự động hóa, tính thời gian thực và tính tự chủ (đưa ra kết quả kèm độ tin cậy, thích ứng theo chất lượng ảnh đầu vào).

3.5 Kỹ thuật và phương pháp cốt lõi

3.5.1 Hệ thống mã hóa hành động khuôn mặt FACS

Hệ thống mã hóa hành động khuôn mặt (Facial Action Coding System - FACS) do Ekman và Friesen đề xuất là một hệ thống dựa trên quan sát viên con người, được thiết kế để phát hiện các thay đổi tinh vi của cơ mặt. FACS gồm 44 đơn vị hành động (action unit - AU), trong đó 30 đơn vị liên quan trực tiếp đến sự co của một nhóm cơ mặt cụ thể. Các AU có thể xuất hiện riêng lẻ hoặc theo tổ hợp (đã quan sát được hơn 7000 tổ hợp khác nhau), được mã hóa đối xứng hoặc bất đối xứng, và đo cường độ bằng thang 5 mức. Bản thân FACS chỉ mang tính mô tả, không gắn nhãn cảm xúc; muốn suy ra cảm xúc cần chuyển sang các hệ thống như EMFACS.

3.5.2 Trích xuất đặc trưng hình học

Đặc trưng hình học (geometric feature) biểu diễn hình dạng và vị trí của các thành phần khuôn mặt (miệng, mắt, lông mày, mũi). Tian và cộng sự xây dựng các **mô hình đa trạng thái** (multi-state models) để theo vết: mô hình ba trạng thái cho môi (mở, đóng, mím chặt), mô hình hai trạng thái (mở/đóng) cho mỗi mắt, mô hình một trạng thái cho lông mày và má. Các tham số được tính theo tỷ lệ so với khung tham chiếu nhằm loại bỏ ảnh hưởng của chuyển động và tỷ lệ. Mô hình diện mạo chủ động (Active Appearance Model - AAM) và mô hình khung dây 3D cũng được dùng để giảm thao tác thủ công và xử lý chuyển động đầu lớn.

3.5.3 Trích xuất đặc trưng ngoại hình

Đặc trưng ngoại hình (appearance feature) biểu diễn thay đổi kết cấu da như nếp nhăn, rãnh mũi-má. **Sóng con Gabor** (Gabor wavelets) được dùng rộng rãi để trích xuất các hệ số đa tỷ lệ, đa hướng, áp dụng cho các vị trí cụ thể hoặc toàn bộ ảnh khuôn mặt. Chương sách dẫn nhiều nghiên cứu cho thấy đặc trưng Gabor và phân tích thành phần độc lập cho kết quả tốt; tuy nhiên Gabor đơn thuần kém hiệu quả khi đối tượng không đồng nhất hoặc có chuyển động đầu. Kết quả thực nghiệm cho thấy **kết hợp cả đặc trưng hình học và ngoại hình** (đặc trưng lai) giúp cải thiện hiệu suất nhận dạng cho hầu hết các AU.

3.6 Quy trình hoạt động chi tiết

3.6.1 Tiền xử lý và thu thập khuôn mặt

Phần lớn hệ thống chỉ xử lý khuôn mặt chính diện hoặc gần chính diện. Để phát hiện khuôn mặt, chương sách dẫn các phương pháp kinh điển như mạng nơ-ron của Rowley, phương pháp thống kê của Schneiderman–Kanade và bộ phát hiện thời gian thực của Viola–Jones dựa trên các đặc trưng chữ nhật. Để xử lý chuyển động đầu ngoài mặt phẳng, hệ thống dùng ước lượng tư thế đầu theo hai nhóm: phương pháp dựa trên mô hình 3D (ví dụ mô hình đầu hình trụ ước lượng 6 bậc tự do theo thời gian thực, kết hợp AAM và cơ chế tái đăng ký để chống tích lũy sai số) và phương pháp dựa trên ảnh 2D (ví dụ dùng mạng nơ-ron phân loại tư thế thành ba lớp: chính diện/gần chính diện, nghiêng/nhìn nghiêng, và các trường hợp khác). Quá trình phân tích biểu cảm chỉ áp dụng cho khuôn mặt chính diện và gần chính diện.

3.6.2 Trích xuất đặc trưng

Sau khi định vị khuôn mặt, hệ thống trích xuất đặc trưng hình học, đặc trưng ngoại hình hoặc đặc trưng lai như đã trình bày. Để loại bỏ ảnh hưởng của tỷ lệ, chuyển động và ánh sáng, ảnh được căn chỉnh và chuẩn hóa về một khuôn mặt chuẩn (2D hoặc 3D), sau đó đo đặc trưng tương đối so với ảnh tham chiếu là khuôn mặt trung tính.

3.6.3 So khớp, phân loại hoặc nhận dạng

Bước cuối nhận dạng biểu cảm dựa trên đặc trưng đã trích xuất. Nhiều bộ phân loại được áp dụng: mạng nơ-ron (NN), máy học vector hỗ trợ (SVM), phân tích biệt thức tuyến tính (LDA), K-láng giềng gần nhất, hồi quy logistic đa thức (MLR), mô hình Markov ẩn (HMM), mạng Bayes mở rộng cây (TAN), RankBoost và các bộ phân loại dựa trên luật. Hai hướng chính:

- **Dựa trên khung hình:** Chỉ dùng thông tin của ảnh hiện tại (có hoặc không có khung tham chiếu). Ví dụ Tian và cộng sự dùng mạng nơ-ron ba lớp đạt độ chính xác 95.5% cho 16 AU và tổ hợp; hệ thống SVM kết hợp MLR đạt 91.5% cho sáu biểu cảm cơ bản.
- **Dựa trên chuỗi:** Khai thác thông tin thời gian của chuỗi bằng HMM, mạng nơ-ron hồi quy hoặc bộ phân loại dựa trên luật. Các hệ thống này phù hợp để nhận dạng AU trong hành vi tự phát, nơi đối tượng đa dạng và có chuyển động đầu, che khuất.

3.7 Phân tích đa phương thức và bộ dữ liệu

Chương sách nhấn mạnh biểu cảm khuôn mặt chỉ là một trong nhiều kênh giao tiếp phi ngôn ngữ, do đó việc tích hợp với cử chỉ, ngữ điệu và lời nói là một hướng quan trọng. Ví dụ, kết hợp đặc trưng khuôn mặt với cử chỉ cơ thể trên bộ dữ liệu FABO nâng độ chính xác lên 85%, cao hơn so với chỉ dùng riêng khuôn mặt hoặc cơ thể. Về dữ liệu, chương sách tổng hợp các bộ chuẩn thường dùng như Cohn–Kanade (bộ dữ liệu được sử dụng phổ biến nhất, gán nhãn FACS), JAFFE, MMI, RU-FACS (biểu cảm tự phát), FABO (mặt và cử chỉ cơ thể), cùng các bộ 3D/4D là BU-3DFE và BU-4DFE.

3.8 Các câu hỏi mở

Chương sách kết lại bằng bảy câu hỏi mở định hướng nghiên cứu tương lai: (1) con người nhận dạng biểu cảm như thế nào; (2) có phải phân tích càng chi tiết càng tốt; (3) có cách mã hóa biểu cảm nào tốt hơn cho máy tính; (4) làm sao thu được nhãn thực tế tin cậy; (5) làm sao nhận dạng biểu cảm trong đời sống thực với chuyển động đầu, ảnh độ phân giải thấp, thiếu khuôn mặt trung tính và biểu cảm cường độ thấp; (6) khai thác thông tin thời gian ra sao; (7) tích hợp với các phương thức khác như thế nào. Trong đó, câu hỏi về **khả năng tổng quát hóa trong môi trường thực** chính là vấn đề mà bài báo SOTA hiện đại trực tiếp giải quyết.

3.9 Ưu điểm và hạn chế từ góc nhìn giáo trình

Ưu điểm:

- Cung cấp khung khái niệm chặt chẽ và toàn diện (cấu trúc ba bước AFEEA, không gian bài toán nhiều chiều, tiêu chí hệ thống lý tưởng), đặt nền móng thuật ngữ cho cả lĩnh vực.
- Hệ thống FACS và các đơn vị hành động cho phép mô tả biểu cảm ở mức tinh vi, có cơ sở giải phẫu rõ ràng và khả năng diễn giải cao.
- Đặc trưng thủ công (hình học, ngoại hình) dễ diễn giải, yêu cầu ít dữ liệu huấn luyện; đặc trưng lại cho kết quả tốt trong điều kiện kiểm soát.

Hạn chế:

- Phụ thuộc nhiều vào đặc trưng thủ công và bước căn chỉnh, nhạy cảm với ánh sáng, tư thế, độ phân giải và sự khác biệt cá nhân.
- Phần lớn hệ thống giả định khuôn mặt chính diện, có khung trung tính tham chiếu và biểu cảm chủ ý; khó áp dụng cho biểu cảm tự phát trong thế giới thực.
- Sử dụng các bộ dữ liệu nhỏ, đồng nhất khiến **khả năng tổng quát hóa chéo miền chưa được giải quyết** - đây chính là rào cản mở mà các phương pháp học sâu hiện đại như CAFE kế thừa và khắc phục.

4 Nghiên cứu bài báo khoa học tiên tiến

4.1 Thông tin bài báo

- **Tên bài báo:** *Generalizable Facial Expression Recognition*.
- **Tác giả:** Yuhang Zhang, Xiuqi Zheng, Chenyi Liang, Jiani Hu, và Weihong Deng.
- **Đơn vị công tác:** Beijing University of Posts and Telecommunications (BUPT).
- **Nơi xuất bản:** Hội nghị Châu Âu về Thị giác Máy tính (*European Conference on Computer Vision - ECCV*), năm 2024.
- **Xếp hạng hội nghị:** Rank A* (Hội nghị hàng đầu thế giới về Computer Vision).
- **Liên kết (Paper):** <https://eccv.ecva.net/virtual/2024/poster/718>
- **Mã nguồn chính thức:** <https://github.com/zyh-uaiaaaa/Generalizable-FER>
- **Từ khóa chính:** Facial Expression Recognition (FER), Zero-shot Generalization, Mask Learning, CLIP.

4.2 Hệ thống dữ liệu thực nghiệm (Datasets)

Trong nghiên cứu này, tác giả đã tiến hành thực nghiệm trên 05 bộ dữ liệu phổ biến nhất hiện nay trong lĩnh vực FER. Để đảm bảo tính nhất quán, tất cả dữ liệu được đưa về chuẩn 07 lớp cảm xúc cơ bản. Chi tiết các bộ dữ liệu như sau:

- **RAF-DB (Real-world Affective Faces Database):**
 - *Đặc điểm:* Chứa 15.339 ảnh khuôn mặt từ thực tế, được gán nhãn bởi 40 chuyên gia.
 - *Phân chia:* 12.271 ảnh huấn luyện và 3.068 ảnh kiểm thử.
 - *Liên kết:* <https://www.kaggle.com/datasets/shuvoalok/raf-db-dataset>
- **FERPlus:**
 - *Đặc điểm:* Là phiên bản cải tiến của FER2013 với nhãn sạch hơn và độ tin cậy cao hơn.
 - *Phân chia:* 28.709 ảnh huấn luyện và 3.589 ảnh kiểm thử.

– Liên kết: <https://www.kaggle.com/datasets/arnabkumarroy02/ferplus>

- **AffectNet:**

– *Đặc điểm:* Bộ dữ liệu quy mô lớn nhất hiện nay. Trong bài báo này, tác giả tập trung vào 7 lớp cảm xúc cơ bản.

– *Phân chia:* 286.564 ảnh huấn luyện và 4.000 ảnh kiểm thử.

– Liên kết: <https://www.kaggle.com/datasets/mstjebashazida/affectnet>

- **SFEW 2.0 (Static Facial Expressions in the Wild):**

– *Đặc điểm:* Tập dữ liệu nhỏ, trích xuất từ các phân cảnh phim thực tế, có độ khó cao do điều kiện ánh sáng và góc độ.

– *Phân chia:* 958 mẫu huấn luyện, 436 mẫu hiệu chỉnh (validation) và 372 mẫu kiểm thử.

– Liên kết: <https://www.kaggle.com/datasets/vlntnstarodub/datasetsfew>

- **MMA (Multi-Modal Affective):**

– *Đặc điểm:* Bộ dữ liệu lớn thu thập từ Internet, tập trung nhiều vào người gốc Âu và Mỹ.

– *Phân chia:* 92.968 mẫu huấn luyện, 17.356 mẫu hiệu chỉnh và 17.356 mẫu kiểm thử.

– Liên kết: <https://www.kaggle.com/datasets/mahmoudima/mma-facial-expression>

4.3 Động lực nghiên cứu và ý tưởng đề xuất

Động lực chính của nghiên cứu này xuất phát từ thực tế rằng các phương pháp tiên tiến nhất hiện nay trong lĩnh vực nhận dạng cảm xúc khuôn mặt thường suy giảm đáng kể về độ chính xác khi áp dụng trên các tập dữ liệu kiểm tra có miền khác biệt so với tập dữ liệu huấn luyện. Các mô hình hiện hành có xu hướng học quá khớp với dữ liệu nguồn, ghi nhớ cả những đặc điểm riêng của miền huấn luyện thay vì tập trung vào các đặc trưng biểu cảm mang tính phổ quát.

Vấn đề thực tiễn đặt ra là những hạn chế cố hữu của các phương pháp tổng quát hóa hoặc thích ứng miền truyền thống. Để xử lý sự khác biệt về dữ liệu, các phương pháp này thường yêu cầu hệ thống phải thu thập trước các mẫu từ miền dữ liệu đích nhằm tinh chỉnh lại mô hình. Tuy nhiên, trong triển khai thực tế, điều kiện này khó khả thi. Phân phối hoặc đặc điểm của các mẫu kiểm tra

mà hệ thống gặp phải thường không thể biết trước, do đó việc tiếp cận dữ liệu mục tiêu để huấn luyện lại là bất khả thi.

Bài toán này có ý nghĩa quan trọng vì phản ánh đúng rào cản lớn nhất trong việc đưa các mô hình trí tuệ nhân tạo vào ứng dụng thực tiễn. Để hệ thống có giá trị sử dụng cao, nghiên cứu đặt mục tiêu nâng cao khả năng tổng quát hóa theo hướng zero-shot, tức là mô hình có thể hoạt động hiệu quả trên nhiều tập dữ liệu kiểm tra chưa từng thấy, với điều kiện chỉ sử dụng duy nhất một tập dữ liệu huấn luyện ban đầu. Hướng tiếp cận này được định nghĩa là bài toán nhận dạng cảm xúc khuôn mặt có khả năng tổng quát hóa.

Dựa trên bối cảnh đó, nghiên cứu được định hình nhằm tránh việc mô hình học các đặc điểm thiên lệch từ dữ liệu nguồn. Giải pháp đề xuất lấy cảm hứng từ cơ chế nhận thức tự nhiên của con người: hệ thống thị giác thường nhận diện các đặc trưng chung của khuôn mặt trước, sau đó mới tách biệt và chọn lọc các yếu tố liên quan đến biểu cảm để đánh giá. Phương pháp này tận dụng một mô hình nền tảng lớn để trích xuất đặc trưng khuôn mặt mang tính tổng quát, sau đó huấn luyện mô hình nhận dạng để tạo mặt nạ nhằm lọc ra các thông tin biểu cảm hữu ích. Cách tiếp cận này kỳ vọng sẽ giải quyết hiệu quả vấn đề tổng quát hóa, đồng thời khắc phục rào cản triển khai trong thực tiễn.

4.4 Phát biểu bài toán và phạm vi nghiên cứu

Nghiên cứu này tập trung vào bài toán nhận dạng cảm xúc khuôn mặt với mục tiêu nâng cao khả năng tổng quát hóa. Thay vì chỉ hướng đến việc đạt độ chính xác tối đa trên cùng một phân phối dữ liệu, phương pháp được đề xuất đặt trọng tâm vào việc cải thiện khả năng tổng quát hóa theo hướng zero-shot, tức là mô hình có thể hoạt động hiệu quả trên các tập dữ liệu kiểm tra chưa từng xuất hiện trong quá trình huấn luyện, nơi phân phối dữ liệu có sự khác biệt so với tập huấn luyện ban đầu.

Về cấu trúc dữ liệu, trong giai đoạn huấn luyện, đầu vào là một tập dữ liệu ảnh khuôn mặt duy nhất $D_{train} = \{(x_i, y_i)\}$, trong đó x_i là hình ảnh khuôn mặt và y_i là nhãn cảm xúc tương ứng. Về mặt kỹ thuật, hệ thống tiếp nhận các đặc trưng khuôn mặt F được trích xuất và cố định trọng số từ một mô hình ngôn ngữ – hình ảnh quy mô lớn, kết hợp với đặc trưng f được sinh ra từ một kiến trúc mạng học sâu khởi tạo mới, có nhiệm vụ tạo mặt nạ. Trong giai đoạn dự đoán ở môi trường thực tế, đầu vào là tập ảnh $D_{real} = \{(\tilde{x}_i, y_i)\}$ từ các miền dữ liệu đích mà hệ thống chưa từng quan

sát, và hoàn toàn không có thông tin tiên nghiệm về phân phối dữ liệu.

Đầu ra mong đợi của hệ thống là kết quả phân loại, xác định ảnh đầu vào thuộc về một trong bảy lớp cảm xúc cơ bản ($L = 7$), bao gồm: ngạc nhiên, sợ hãi, ghê tởm, hạnh phúc, buồn bã, tức giận và trung tính.

Để đảm bảo giải pháp có thể áp dụng trực tiếp trong thực tế, nghiên cứu xác lập phạm vi và ranh giới kỹ thuật cụ thể như sau:

- **Thứ nhất**, hệ thống tuyệt đối không sử dụng dữ liệu từ miền đích. Khác với các phương pháp thích ứng miền, mô hình chỉ được phép huấn luyện trên một tập dữ liệu nguồn duy nhất, không được tiếp cận bất kỳ mẫu nào từ miền dữ liệu đích để tinh chỉnh.
- **Thứ hai**, nghiên cứu không đặt mục tiêu tối ưu hóa để đạt độ chính xác cao nhất trên miền nguồn. Trọng tâm là đánh giá khả năng tổng quát hóa đa miền. Các phương pháp trước đây thường đạt kết quả rất cao trên miền nguồn nhưng lại suy giảm mạnh khi áp dụng trên miền mới do hiện tượng ghi nhớ dữ liệu cục bộ.
- **Thứ ba**, phạm vi phương pháp luận được giới hạn ở việc học một mặt nạ hàm sigmoid. Mô hình không học lại toàn bộ đặc trưng khuôn mặt từ đầu, mà chỉ tạo ra mặt nạ nhằm chọn lọc các thông tin liên quan đến cảm xúc từ khối đặc trưng khuôn mặt được trích xuất bởi mô hình ngôn ngữ – hình ảnh. Khi chuyển sang giai đoạn dự đoán thực tế, các khối hỗ trợ tính toán trong quá trình huấn luyện sẽ bị loại bỏ hoàn toàn, mô hình chỉ giữ lại khối phân loại để đưa ra kết quả cuối cùng.

4.5 Giải pháp đề xuất CAFE

4.5.1 Ý tưởng cốt lõi

Nghiên cứu đề xuất một phương pháp mới mang tên CAFE, được thiết kế chuyên biệt để mô phỏng cách con người nhận thức biểu cảm khuôn mặt. Khác với các phương pháp truyền thống thường huấn luyện một mạng nơ-ron từ đầu để trích xuất toàn bộ đặc trưng, dẫn đến việc mạng học luôn những thông tin đặc thù của miền dữ liệu và gây ra tình trạng học quá khớp, CAFE chia bài toán thành hai bước tiệm cận với hệ thống thị giác tự nhiên. Bước thứ nhất định vị và trích xuất các đặc trưng chung của khuôn mặt nhằm loại bỏ yếu tố khác biệt về miền dữ liệu. Bước thứ hai chỉ chọn lọc các đặc trưng liên quan mật thiết đến cảm xúc để đưa ra quyết định.


Để hiện thực hóa điều này, nguyên lý cốt lõi của CAFE là không học lại đặc trưng khuôn mặt từ đầu. Thay vào đó, kiến trúc tận dụng khả năng tổng quát hóa của một mô hình ngôn ngữ - hình ảnh lớn để lấy các đặc trưng khuôn mặt cố định, sau đó huấn luyện một mô hình chuyên biệt học cách tạo ra một mặt nạ nhằm chất lọc thông tin hữu ích.

4.5.2 Luồng dữ liệu qua hệ thống

Quá trình xử lý một ảnh đầu vào x được thiết kế theo luồng phân nhánh song song trước khi tiến hành hợp nhất và tính toán tối ưu hóa đa nhiệm. Cụ thể, luồng dữ liệu diễn ra như sau:

- **Nhánh trích xuất khuôn mặt:** Ảnh đầu vào x được đưa qua mô hình ngôn ngữ - hình ảnh lớn để trích xuất khối đặc trưng khuôn mặt tổng quát F . Trong nhánh này, trọng số của mạng được đóng băng hoàn toàn.
- **Nhánh tạo mặt nạ:** Đồng thời, ảnh x đi qua mô hình nhận dạng khởi tạo mới để trích xuất đặc trưng biểu cảm thô f . Dữ liệu này sau đó được thay đổi kích thước và truyền qua hàm kích hoạt sigmoid để biến đổi thành ma trận mặt nạ M_s .
- **Hợp nhất dữ liệu:** Mặt nạ M_s được nhân trực tiếp với đặc trưng khuôn mặt F theo nguyên lý chú ý không gian, tạo ra khối đặc trưng biểu cảm đã chọn lọc $\tilde{F} = M_s F$.
- **Tối ưu hóa đa nhiệm:** Khối đặc trưng $\tilde{F}$ tiếp tục được sử dụng đồng thời để tính toán hàm mất mát phân loại truyền thống, đồng thời truyền qua hai khối kiến trúc mới là khối phân tách kênh và khối đa dạng kênh. Quá trình này giúp tối ưu hóa mặt nạ và đảm bảo mạng không rơi vào trạng thái học quá khớp.

Cấu trúc chi tiết về sự tương tác giữa các nhánh mạng, luồng di chuyển của các khối đặc trưng và vị trí áp dụng các hàm mất mát thành phần được minh họa cụ thể trong Hình 1 [8].



Hình 1: Sơ đồ kiến trúc tổng thể của phương pháp CAFE với cơ chế học mặt nạ sigmoid và các mô-đun tối ưu hóa đa nhiệm (Trích từ Hình 2 trong [8]).

4.5.3 Kiến trúc chi tiết và các công thức cốt lõi

1. Khai thác đặc trưng khuôn mặt cố định

Thay vì để mạng nhận dạng tự học đặc trưng từ đầu, nghiên cứu ứng dụng kiến trúc CLIP đã được tiền huấn luyện trên các tập dữ liệu quy mô lớn nhằm trích xuất khối đặc trưng khuôn mặt tổng quát F . Điểm mấu chốt của thiết kế này là toàn bộ trọng số của mô hình CLIP được đóng băng trong suốt vòng đời huấn luyện. Kỹ thuật này đóng vai trò như một màng lọc bảo vệ, ngăn chặn hệ thống vô tình nội suy và ghi nhớ các đặc trưng nhiễu từ tập dữ liệu huấn luyện cục bộ.

2. Học mặt nạ phân bổ

Mạng nhận dạng đảm nhiệm vai trò học cách trích xuất ma trận đặc trưng f , sau đó tính chỉnh kích thước để định hình thành mặt nạ M . Nhằm mục đích chuẩn hóa và gia tăng tính phi tuyến, mặt nạ này được đưa qua hàm kích hoạt sigmoid:

$$M_s = \text{Sigmoid}(M) \quad (1)$$

Việc áp dụng hàm kích hoạt này ép các giá trị phân phối về khoảng $[0, 1]$, hoạt động tương tự như một giá trị xác suất nhằm chọn lọc các kênh đặc trưng hữu ích. Từ đó, khối đặc trưng biểu cảm cuối cùng được tính toán thông qua tích chập điểm:

$$\tilde{F} = M_s F \quad (2)$$

3. Mô-đun phân tách kênh và loại bỏ lớp kết nối đầy đủ

Trong các kiến trúc thị giác máy tính truyền thống, lớp FC thường được đặt ở tầng cuối cùng để thực hiện phân loại. Tuy nhiên, khả năng biểu diễn quá mức của lớp này dễ dẫn đến hiện tượng ghi nhớ nhãn cục bộ. Nhằm loại bỏ hoàn toàn sự phụ thuộc vào lớp FC, mô-đun phân tách tiến hành chia cắt trực tiếp khối đặc trưng $\tilde{F}$ thành bảy phần dọc theo chiều kênh, tương ứng với bảy lớp cảm xúc cơ bản.

Sau khi kết hợp với cơ chế rút kênh ngẫu nhiên M_{drop} nhằm ép mạng lan truyền sự chú ý lên toàn bộ không gian đặc trưng, hệ thống áp dụng phép toán gộp cực đại trên từng phần để trực tiếp tạo ra các giá trị xác suất phân loại dự đoán F^d . Quá trình tối ưu hóa khối này được thực hiện thông qua hàm mất mát phân tách l_{sep} mà không cần cập nhật trọng số FC:

$$l_{sep} = -\frac{1}{N} \sum_{i=1}^N \left(\log \frac{e^{F_{y_i}^d}}{\sum_{j=1}^L e^{F_j^d}} \right) \quad (3)$$

4. Hàm mất mát đa dạng kênh

Nhằm đảm bảo bảy khối đặc trưng đại diện cho bảy biểu cảm không chứa thông tin dư thừa hoặc trùng lặp, hệ thống trích xuất ra giá trị lớn nhất dọc theo chiều kênh của mỗi phần, ký hiệu là $\tilde{F}_{max}$. Hàm mất mát đa dạng kênh l_{div} được thiết kế để nới rộng các giá trị cực đại này lớn nhất có thể, từ đó ép các kênh trong mỗi phần trở nên phong phú và có ranh giới quyết định tách biệt. Phương trình hàm mất mát được định nghĩa:

$$l_{div} = 1 - \frac{1}{N_C} \sum_{i=1}^N \sum_{j=1}^L \tilde{F}_{max_{ij}} \quad (4)$$

5. Tổng hàm mất mát huấn luyện

Để hệ thống CAFE hội tụ và học được một mặt nạ tình lọc tối ưu, tổng hàm mất mát trong quá trình huấn luyện được định nghĩa là sự kết hợp tuyến tính của cả ba thành phần chi phí:

$$l_{train} = l_{cls} + \lambda l_{sep} + \beta l_{div} \quad (5)$$

Trong các hệ thức toán học trên, các biến và ký hiệu được quy ước như sau:

- N biểu thị số lượng mẫu ảnh trong một cấu trúc dữ liệu tính toán (chẳng hạn như trong một lô nhỏ).
- C là tổng số chiều của khối đặc trưng. Đối với cấu trúc mạng phần dư, giá trị thực nghiệm

thường đặt $C = 512$.

- L đại diện cho số lượng các lớp cảm xúc cơ bản cần phân loại, trong phạm vi nghiên cứu này $L = 7$.
- y_i là nhãn cảm xúc thực tế của mẫu dữ liệu thứ i . Các chỉ số i và j được sử dụng để duyệt qua các chiều không gian của ma trận.
- Khối đặc trưng F , ma trận mặt nạ ban đầu M , và mặt nạ chuẩn hóa M_s đều chia sẻ cùng kích thước không gian $N \times C$.
- F^d là ma trận chứa các giá trị xác suất dự đoán kích thước $N \times L$. Trong đó, $F_{y_i}^d$ là giá trị tương ứng với nhãn đúng của mẫu thứ i , và F_j^d là xác suất dự đoán cho lớp thứ j .
- $\tilde{F}_{max_{ij}}$ đại diện cho giá trị lớn nhất trích xuất được thuộc về bức ảnh thứ i và lớp cảm xúc thứ j trong ma trận cực đại kích thước $N \times L$.
- c là hằng số chuẩn hóa tỷ lệ thuận với số kênh phân bố cho mỗi lớp (thực nghiệm sử dụng $c = 73$).
- λ và β là các siêu tham số được cấu hình nhằm cân bằng mức độ đóng góp của từng khía cạnh tối ưu, với các giá trị được tinh chỉnh là $\lambda = 1.5$ và $\beta = 5$.

Trong cơ chế vận hành, l_{cls} đảm bảo mặt nạ định hướng đúng đặc trưng để phân loại chính xác, l_{sep} hỗ trợ gia tăng tính tổng quát thông qua việc loại bỏ tham số của lớp FC, và l_{div} chịu trách nhiệm làm phong phú không gian biểu diễn biểu cảm. Khi bước vào giai đoạn suy diễn thực tế, toàn bộ các khối tính toán thuộc l_{sep} và l_{div} sẽ được loại bỏ khỏi biểu đồ tính toán. Luồng dữ liệu suy diễn chỉ duy trì nhánh trích xuất đặc trưng thuần túy, đảm bảo mô hình hoạt động tinh gọn và tối ưu hóa thời gian thực thi.

4.5.4 Mục tiêu kỹ thuật và tóm lược quy trình vận hành

Mục tiêu cốt lõi của nghiên cứu này là cải thiện khả năng tổng quát hóa zero-shot của các mô hình FER khi đối mặt với các tập dữ liệu kiểm tra hoàn toàn mới có sự khác biệt về miền dữ liệu. Cụ thể, hệ thống phải đảm bảo khả năng dự đoán chính xác trong khi chỉ được phép sử dụng duy nhất một tập dữ liệu nguồn để huấn luyện. Nghiên cứu xác lập giới hạn nghiêm ngặt là tuyệt đối không

tiếp cận bất kỳ mẫu dữ liệu nào, dù có nhãn hay chưa gán nhãn, từ miền dữ liệu đích. Mục tiêu này trực tiếp giải quyết rào cản triển khai trong thực tế, nơi phân phối của các mẫu dữ liệu kiểm tra thường là biến số không thể dự báo trước.

Nhằm đạt được mục tiêu trên, phương pháp CAFE được thiết kế để mô phỏng cơ chế nhận thức biểu cảm của con người qua quy trình ba bước trọng tâm:

- **Khai thác đặc trưng khuôn mặt cố định:** Hệ thống sử dụng mô hình ngôn ngữ - hình ảnh lớn như CLIP để trích xuất đặc trưng khuôn mặt tổng quát. Toàn bộ trọng số của khối đặc trưng này được đóng băng trong suốt quá trình huấn luyện.
- **Học mặt nạ sigmoid:** Mạng khởi tạo một mô hình FER mới nhằm học cách tạo ra một mặt nạ đặc trưng. Mặt nạ này được xử lý qua hàm kích hoạt sigmoid để chuẩn hóa giá trị về khoảng xác suất, sau đó nhân trực tiếp với khối đặc trưng khuôn mặt cố định để tinh lọc thông tin biểu cảm.
- **Tối ưu hóa đa nhiệm không dùng lớp FC:** Hệ thống loại bỏ hoàn toàn sự phụ thuộc vào lớp FC để giảm thiểu rủi ro học quá khớp. Khối đặc trưng sau tinh lọc được chia làm bảy phần dọc theo chiều kênh. Thông qua phép toán max pooling trên mỗi phần, mạng trực tiếp tạo ra các giá trị logit phân loại, kết hợp với hàm mất mát đa dạng kênh để tăng cường độ tách biệt giữa các biểu cảm.

4.5.5 Phân tích cơ sở khoa học và tính hiệu quả của phương pháp

Sự vượt trội của kiến trúc CAFE trong các thực nghiệm đa miền xuất phát từ việc thiết kế một cơ chế phòng vệ nhiều lớp, giúp hệ thống chống lại hiện tượng học quá khớp một cách bền vững. Các luận điểm chính giải thích cho hiệu quả của phương pháp bao gồm:

Ngăn chặn sự ghi nhớ miền dữ liệu cục bộ

Việc đóng băng trọng số của mô hình CLIP đóng vai trò như một chốt chặn kỹ thuật, đảm bảo nền tảng đặc trưng luôn duy trì được tính tổng quát hóa cao. Cơ chế này ngăn chặn hiệu quả việc mô hình FER học lấy các đặc điểm nhiễu đặc thù từ tập huấn luyện như điều kiện ánh sáng, bối cảnh môi trường hoặc góc chụp ảnh. Bằng cách giữ nguyên tri thức từ mô hình lớn, hệ thống chỉ tập trung vào việc học cách khai thác thông tin thay vì thay đổi bản chất đặc trưng.

Loại bỏ rủi ro từ lớp kết nối đầy đủ

Trong các cấu trúc học sâu truyền thống, lớp FC sở hữu năng lực học tập và biểu diễn quá mạnh, dẫn đến xu hướng ghi nhớ nhân của tập huấn luyện thay vì học các quy luật trừu tượng. Việc chuyển đổi bài toán nhận dạng thành dạng chia cắt kênh và gom nhóm trực tiếp đã triệt tiêu hoàn toàn khả năng học thuộc lòng của lớp mạng này. Điều này buộc mô hình phải dựa vào sự phân bố đặc trưng trên các kênh nơ-ron để đưa ra quyết định, từ đó gia tăng độ tin cậy khi gặp các dữ liệu lạ.

Tác dụng chuẩn hóa và tính phi tuyến của hàm sigmoid

Hàm kích hoạt sigmoid không chỉ bổ sung tính phi tuyến cần thiết cho mô hình mà còn ép các giá trị của mặt nạ vào một khoảng chuẩn hóa. Nếu thiếu đi hàm này, hiệu suất của hệ thống sẽ suy giảm nghiêm trọng do mặt nạ mất đi tính chất xác suất trong việc chọn lọc đặc trưng. Hàm sigmoid giúp mô hình thực hiện cơ chế chú ý một cách mềm dẻo, giảm thiểu tình trạng mặt nạ bị điều chỉnh quá mức theo dữ liệu khuôn mặt đầu vào cụ thể.

Đơn giản hóa nhiệm vụ tối ưu hóa

Thay vì phải đảm nhận trọng trách nặng nề là học lại toàn bộ quy trình trích xuất đặc trưng biểu cảm từ con số không, việc chỉ học một mặt nạ để chọn lọc thông tin trên nền tảng tri thức có sẵn là một nhiệm vụ tối ưu hóa nhẹ nhàng và hiệu quả hơn. Thiết kế này cho phép mô hình trích xuất được các quy luật cơ bản của biểu cảm khuôn mặt mà không đòi hỏi một mạng nơ-ron có cấu trúc quá phức tạp. Hệ quả là tính bền vững của mô hình được gia tăng đáng kể, đồng thời nâng cao khả năng thích ứng chéo giữa nhiều bộ dữ liệu khác nhau trong môi trường thực tế.

4.6 Thực nghiệm minh họa và đánh giá kết quả

Để chứng minh tính hiệu quả của phương pháp CAFE, hệ thống thực nghiệm được thiết kế tập trung vào khả năng tổng quát hóa chéo miền. Quá trình đánh giá được thực hiện thông qua việc so sánh với các phương pháp tiên tiến nhất và phân tích chuyên sâu về sự đóng góp của từng thành phần kiến trúc.

4.6.1 Thiết lập thực nghiệm và các phương pháp so sánh

Nghiên cứu sử dụng năm bộ dữ liệu phổ biến bao gồm RAF-DB, FERPlus, AffectNet, SFEW2.0 và MMA. Tất cả dữ liệu đều được quy chuẩn về bảy lớp cảm xúc cơ bản. Giao thức thực nghiệm chính được áp dụng là khả năng tổng quát hóa zero-shot chéo miền. Theo giao thức này, mô hình

chỉ được huấn luyện trên một miền nguồn duy nhất và tiến hành kiểm tra trực tiếp trên các miền đích còn lại mà không sử dụng bất kỳ mẫu dữ liệu nào từ miền đích để tinh chỉnh.

Hệ thống được so sánh với các phương pháp tiên tiến nhất như SCN, RUL, EAC và OFER. Ngoài ra, một phương pháp nền tảng được xây dựng bằng cách đóng băng mô hình CLIP và tinh chỉnh một lớp kết nối đầy đủ nhằm xác định xem sự cải thiện hiệu suất đến từ kiến trúc mặt nạ hay chỉ đơn thuần do sức mạnh của mô hình lớn. Nghiên cứu cũng thực hiện huấn luyện từ đầu đối với mạng xương sống để kiểm chứng tính bền vững của giải pháp.

4.6.2 Chỉ số đo lường hiệu suất

Trong bài toán nhận dạng cảm xúc khuôn mặt, việc lựa chọn chỉ số đo lường đóng vai trò quyết định đến tính khách quan của kết quả. Nghiên cứu sử dụng hai chỉ số chính:

- **Độ chính xác tổng thể:** Phản ánh tỷ lệ phần trăm các mẫu được dự đoán đúng trên toàn bộ tập dữ liệu kiểm tra. Chỉ số này cung cấp cái nhìn khái quát về hiệu suất chung nhưng có thể gây sai lệch khi tập dữ liệu bị mất cân bằng dữ liệu.
- **Độ chính xác trung bình:** Đây là chỉ số quan trọng nhất, được tính bằng cách lấy trung bình cộng độ chính xác của từng lớp cảm xúc riêng biệt. Do các bộ dữ liệu thực tế thường cực kỳ mất cân bằng, chỉ số này đảm bảo mô hình không “gian lận” bằng cách chỉ ưu tiên nhận diện các lớp chiếm đa số mà bỏ qua các lớp thiểu số. Việc tối ưu hóa dựa trên độ chính xác trung bình phản ánh đúng năng lực tổng quát hóa và tính công bằng của hệ thống đối với mọi trạng thái cảm xúc.

4.6.3 Kết quả thực nghiệm và phân tích chuyên sâu

Kết quả thực nghiệm khẳng định sự vượt trội của phương pháp CAFE so với các giải pháp tiên tiến nhất trên cả năm bộ dữ liệu. Khi huấn luyện trên RAF-DB, CAFE đạt độ chính xác trung bình 63,48% trên các tập kiểm tra chéo, vượt xa mức 54,88% của phương pháp tốt nhất trước đó. Nghiên cứu cắt bỏ cho thấy mọi thành phần trong kiến trúc đều đóng góp tích cực vào hiệu suất. Việc áp dụng mặt nạ giúp nâng độ chính xác trung bình từ 46,67% lên 55,49%. Các mô-đun phân tách và đa dạng tiếp tục cải thiện kết quả lên mức 57,17%. Đặc biệt, nếu loại bỏ hàm kích hoạt sigmoid, hiệu suất sụt giảm nghiêm trọng xuống còn 58,05%, chứng minh vai trò không thể thay thế của nó trong việc chuẩn hóa và chống học quá khớp.

Đáng chú ý, khi loại bỏ mạng xương sống tiền huấn luyện, CAFE vẫn duy trì được hiệu suất ổn định với mức giảm nhẹ, trong khi các phương pháp như EAC bị sụt giảm thê thảm. So sánh với phương pháp tinh chỉnh trực tiếp mô hình CLIP, CAFE cũng tạo ra khoảng cách lớn về độ chính xác. Điều này khẳng định cơ chế tạo mặt nạ mới chính là yếu tố giải phóng sức mạnh tổng quát hóa của các mô hình ngôn ngữ - hình ảnh lớn.

4.7 Liên hệ với chương sách giáo trình nền tảng

Mối quan hệ kỹ thuật giữa lý thuyết nền tảng trong chương sách giáo trình về nhận dạng cảm xúc khuôn mặt và bài báo hiện đại ứng dụng phương pháp CAFE thể hiện một bước tiến hóa rõ rệt của lĩnh vực. Nghiên cứu hiện đại không bác bỏ hoàn toàn hệ thống lý thuyết cũ mà trực tiếp kế thừa cấu trúc cốt lõi. Từ nền tảng đó, nghiên cứu tiến hành thay thế các công cụ phân tích thủ công bằng các cấu trúc mạng học sâu, đồng thời đưa ra lời giải trực tiếp cho những câu hỏi mở mà thế hệ đi trước để lại. Sự chuyển giao và nâng cấp kiến thức giữa hai tài liệu được phân tích chi tiết qua các khía cạnh sau.

4.7.1 Sự kế thừa từ lý thuyết nền tảng

Cấu trúc ba bước tiêu chuẩn: Chương sách giáo trình định nghĩa một hệ thống phân tích biểu cảm khuôn mặt tự động luôn bao gồm ba giai đoạn cơ bản: thu thập khuôn mặt, trích xuất và biểu diễn dữ liệu khuôn mặt, cuối cùng là nhận dạng cảm xúc. Phương pháp đề xuất trong bài báo tuân thủ tuyệt đối triết lý cấu trúc này, nhưng hiện đại hóa từng bước thực thi thông qua việc ứng dụng công cụ tự động chuyên sâu để phát hiện khuôn mặt, sử dụng mô hình ngôn ngữ - hình ảnh để trích xuất và sử dụng cấu trúc tạo mặt nạ để phân loại.

Hệ thống bảy lớp cảm xúc cơ bản: Mặc dù lý thuyết nền tảng có đề cập đến hệ thống mã hóa hành động khuôn mặt nhằm bắt giữ các chuyển động vi tế của cơ mặt, cả hai hệ thống nghiên cứu đều thống nhất sử dụng bảy biểu cảm nguyên mẫu xuất phát từ lý thuyết tâm lý học nền tảng làm mục tiêu phân loại cốt lõi. Các biểu cảm bao gồm: ngạc nhiên, sợ hãi, ghê tởm, hạnh phúc, buồn bã, tức giận và trung tính.

Triết lý thiết kế mô phỏng nhận thức tự nhiên: Tài liệu giáo trình đặt ra một yêu cầu khắt khe là hệ thống máy tính phải có khả năng phân tích biểu cảm khuôn mặt bất chấp sự thay đổi của bối cảnh, giới tính hay nền văn hóa. Phương pháp CAFE đã lấy chính yêu cầu này làm kim chỉ

nam thiết kế. Cụ thể, kiến trúc mô phỏng cơ chế con người định vị các đặc trưng chung của khuôn mặt để loại bỏ sự khác biệt về môi trường trước, sau đó mới tiến hành tách biệt và chọn lọc các đặc trưng biểu cảm. Khung tư duy này là tiền đề dẫn đến sự ra đời của cơ cấu mặt nạ trên nền đặc trưng cố định.

4.7.2 Sự mở rộng và giải quyết các câu hỏi mở

Bài toán tổng quát hóa và thử nghiệm chéo miền: Các nhà nghiên cứu ở thế hệ trước đã vạch ra một giới hạn lớn của lĩnh vực khi các hệ thống thường chỉ được huấn luyện và đánh giá trên cùng một bộ dữ liệu đồng nhất, quy mô nhỏ và được kiểm soát chất lượng ánh sáng nghiêm ngặt. Do đó, khả năng tổng quát hóa của các phương pháp khi đối mặt với môi trường và bối cảnh bất định vẫn là một câu hỏi mở. Kiến trúc CAFE được sinh ra để trực tiếp giải quyết bài toán này. Hệ thống định nghĩa lại quy trình thành nhận dạng cảm xúc khuôn mặt có khả năng tổng quát hóa, trong đó cấu trúc mạng bị ép buộc phải học từ một miền dữ liệu nguồn duy nhất và kiểm chứng độ chính xác trên các tập dữ liệu kiểm tra chưa từng thấy mà không được phép tiến hành bất kỳ tinh chỉnh nào.

Khắc phục sự khác biệt cá nhân: Lý thuyết nền tảng ghi nhận rằng sự khác biệt cá nhân như hình dáng, kết cấu da, sự hiện diện của râu hay kính mắt giữa các chủng tộc và độ tuổi làm suy giảm độ tin cậy của quá trình phân tích đặc trưng. Hướng tiếp cận mới giải quyết triệt để rào cản đa dạng sinh học này bằng cách sử dụng mạng xương sống đã được tiền huấn luyện trên dữ liệu web quy mô khổng lồ, đảm bảo khối đặc trưng khuôn mặt nền tảng bao quát được mọi đặc điểm nhân dạng và môi trường.

4.7.3 Sự thay thế bởi hướng tiếp cận học sâu hiện đại

Thay thế phương pháp trích xuất đặc trưng: Trong các hệ thống kinh điển, để biểu diễn cảm xúc, quy trình phụ thuộc hoàn toàn vào nhóm đặc trưng thủ công. Nhóm này được chia làm hai loại chính: đặc trưng hình học đòi hỏi tính toán tọa độ vật lý bằng mô hình diện mạo chủ động, và đặc trưng ngoại hình sử dụng bộ lọc tần số hoặc luồng quang học để nội suy nếp nhăn. Trong kiến trúc hiện đại, toàn bộ các công cụ thủ công này bị loại bỏ. Hệ thống thay thế bằng đặc trưng học sâu thông qua mạng biến áp thị giác, tự động trích xuất một khối biểu diễn không gian đa chiều. Việc học các khoảng cách vật lý được thay thế bằng một mặt nạ sigmoid nhân trực tiếp vào khối đặc trưng nhằm tự động chất lọc thông tin phi tuyến.

Bước ngoặt trong kiến trúc phân loại: Khâu nhận dạng cảm xúc trong quá khứ thường sử dụng các bộ phân loại như máy học vector hỗ trợ hay hệ chuyên gia dựa trên luật. Nhận ra rằng các lớp kết nối đầy đủ trong mạng nơ-ron có năng lực biểu diễn quá mạnh dẫn đến hiện tượng học quá khớp cục bộ, kiến trúc hiện đại đã loại bỏ hoàn toàn tầng nơ-ron này. Giải pháp thay thế là sử dụng mô-đun phân tách kênh để chia cắt khối biểu diễn thành bảy phần, kết hợp với phép toán gộp cực đại để trực tiếp nội suy xác suất phân loại. Kỹ thuật này đã biến đổi bản chất của bài toán phân loại đa lớp truyền thống thành một dạng tương tự như cơ chế học phân phối nhân.

4.7.4 Phân tích đối sánh các đặc tính kỹ thuật

Để làm rõ sự tiến hóa từ phương pháp phân tích thủ công đến việc ứng dụng sức mạnh của các mô hình học sâu lớn, Bảng 3 dưới đây trình bày nội dung so sánh trực tiếp giữa hai hệ thống nghiên cứu dựa trên các khía cạnh kỹ thuật cốt lõi.

Bảng 3: So sánh đặc tính kỹ thuật giữa hệ thống phân tích truyền thống và phương pháp CAFE hiện đại.

Khía cạnh đối sánh	Lý thuyết nền tảng (Phương pháp truyền thống)	Phương pháp CAFE (Hướng tiếp cận hiện đại)
Mục tiêu cốt lõi	Nhận dạng cảm xúc thông qua hệ thống AFEA gồm ba bước tiêu chuẩn, tập trung nhận diện biểu cảm trong môi trường có kiểm soát ánh sáng.	Cải thiện khả năng tổng quát hóa zero-shot trên các miền dữ liệu hoàn toàn chưa từng thấy, trực tiếp giải quyết sự khác biệt về miền dữ liệu.
Cơ chế biểu diễn dữ liệu	Phụ thuộc hoàn toàn vào đặc trưng thủ công, bao gồm đặc trưng hình học tính toán từ điểm mốc và đặc trưng ngoại hình tính từ kết cấu da.	Phụ thuộc vào đặc trưng học sâu, kế thừa khối đặc trưng tổng quát hóa từ mô hình ngôn ngữ - hình ảnh kết hợp với một mặt nạ tinh lọc.
Tiếp tục ở trang sau...		

Bảng 3 (tiếp theo)

Khía cạnh đối sánh	Lý thuyết nền tảng (Phương pháp truyền thống)	Phương pháp CAFE (Hướng tiếp cận hiện đại)
Quy trình phương pháp chính	Thu thập khuôn mặt, định vị điểm chuẩn thủ công, trích xuất đặc trưng bằng bộ lọc và phân loại bằng học máy kinh điển (SVM, HMM).	Đóng băng trọng số đặc trưng khuôn mặt, huấn luyện mạng tạo mặt nạ sigmoid, áp dụng mô-đun phân tách kênh và hàm mất mát đa dạng kênh.
Yêu cầu về phổ dữ liệu	Đòi hỏi dữ liệu kiểm tra và huấn luyện có sự tương đồng phân phối. Hiệu suất giảm mạnh nếu có sự thay đổi về ánh sáng hoặc sự khác biệt cá nhân.	Chỉ sử dụng duy nhất một miền dữ liệu nguồn để huấn luyện, tuyệt đối không tiếp cận dữ liệu đích, có khả năng chạy trực tiếp chéo miền.
Độ phức tạp tính toán	Phức tạp chủ yếu ở khâu tiền xử lý (cắt ảnh, tính toán tọa độ đặc trưng hình học bằng AAM). Các bộ phân loại ở phần đuôi tương đối nhẹ.	Phức tạp ở quy mô của mạng trích xuất nền tảng nhưng mạng học mặt nạ cực kỳ tinh gọn do loại bỏ hoàn toàn lớp kết nối đầy đủ để chống học quá khớp.
Khả năng ứng dụng thực tiễn	Hoạt động ổn định trong phòng thí nghiệm, nhưng khả năng tổng quát hóa trong thế giới thực được xem là một bài toán chưa có lời giải.	Khả năng triển khai thực tế cao, phù hợp cho các hệ thống mở nơi phân phối dữ liệu và môi trường của người dùng cuối không được biết trước.
<i>Tiếp tục ở trang sau...</i>		

Bảng 3 (tiếp theo)		
Khía cạnh đối sánh	Lý thuyết nền tảng (Phương pháp truyền thống)	Phương pháp CAFE (Hướng tiếp cận hiện đại)
Cơ chế xử lý nhiễu và độ lệch	Loại bỏ độ lệch chuyển động cơ mặt bằng cách tính tỷ lệ tham số so với một ảnh khung hình có khuôn mặt trung tính hoặc căn chỉnh không gian ba chiều.	Tránh học nhiễu cục bộ bằng cách đóng băng khối đặc trưng nền tảng, đồng thời ép mạng học các quy luật biểu cảm đơn giản thông qua hàm mất mát đa dạng kênh.

Tổng hợp lại, lý thuyết trong chương sách giáo trình đóng vai trò thiết lập hệ quy chiếu vững chắc về các bước thực thi và nhận diện chính xác các rào cản ứng dụng. Dựa trên bộ khung đó, phương pháp CAFE đã thay thế toàn bộ hệ thống trích xuất đặc trưng công kênh bằng các công cụ học sâu mạnh mẽ nhất. Sự dịch chuyển thể hệ này đã hiện thực hóa được mục tiêu tối thượng mà nền tảng lý thuyết từng hướng đến: xây dựng một hệ thống hoạt động bền bỉ và nhận dạng chính xác trong sự hỗn loạn của dữ liệu thế giới thực.

4.8 Đánh giá và nhận định

4.8.1 Phân tích các điểm mạnh về mặt kỹ thuật

Thiết kế kiến trúc mô phỏng nhận thức tự nhiên: Điểm mạnh cốt lõi của phương pháp nằm ở cách phân rã bài toán thành hai giai đoạn bám sát cơ chế thị giác của con người. Thay vì xử lý đồng thời, hệ thống sử dụng một mô hình ngôn ngữ - hình ảnh lớn để định vị đặc trưng khuôn mặt một cách tổng quát, sau đó sử dụng một mô hình nhận dạng chuyên biệt học cách tạo mặt nạ để chọn lọc riêng biệt các thông tin biểu cảm. Việc chuyển đổi nhiệm vụ từ học toàn bộ không gian đặc trưng sang chỉ học một mặt nạ lọc giúp giảm tải đáng kể áp lực tính toán cho mạng nơ-ron, cho phép hệ thống tập trung trích xuất các quy luật đơn giản và dễ vận dụng chéo miền hơn.

Khả năng chống học quá khớp đa tầng: Phương pháp này thiết lập một cơ chế phòng ngự chặt chẽ nhằm ngăn chặn hệ thống ghi nhớ các đặc điểm nhiễu của tập huấn luyện:

- *Đóng băng khối đặc trưng nền tảng:* Việc duy trì trạng thái đóng băng toàn bộ trọng số của mô hình nền tảng trong suốt chu kỳ huấn luyện giúp các khối đặc trưng khuôn mặt không bị

biến dạng để chạy theo phân phối cục bộ, qua đó bảo toàn trọn vẹn năng lực tổng quát hóa nguyên bản.

- *Tích hợp hàm kích hoạt sigmoid*: Hàm toán học này bổ sung tính phi tuyến và chuẩn hóa các giá trị của mặt nạ, biến nó thành một bộ lọc xác suất thực thụ. Dữ liệu thực nghiệm chứng minh rằng việc loại bỏ hàm này khiến hệ thống suy giảm nghiêm trọng khả năng chống học vẹt.
- *Loại bỏ lớp kết nối đầy đủ*: Nhận thức được rủi ro ghi nhớ nhần từ năng lực biểu diễn quá mức của lớp mạng này, kiến trúc đề xuất chia cắt khối đặc trưng thành bảy phần độc lập, sau đó ứng dụng phép toán gộp cực đại để tạo thẳng các giá trị xác suất phân loại mà không cần bất kỳ tham số kết nối đầy đủ đặc nào.

Kỹ thuật tối ưu hóa thông minh và khả năng triển khai: Song song với việc phân tách kênh, hệ thống ứng dụng hàm mất mát đa dạng kênh nhằm tối đa hóa các cực trị trong không gian biểu diễn. Kỹ thuật này ép buộc các kênh thông tin thuộc cùng một nhóm biểu cảm phải duy trì sự phong phú và tách biệt rõ rệt, giải quyết triệt để vấn đề chồng chéo ranh giới giữa các lớp cảm xúc. Nhờ đó, giải pháp thể hiện khả năng tổng quát hóa zero-shot xuất sắc, tháo gỡ hoàn toàn rào cản ứng dụng khi có thể nhận dạng chính xác trên các miền dữ liệu xa lạ chỉ với một tập huấn luyện duy nhất.

Tính bền vững và tính độc lập với cấu trúc nền: Hệ thống cho thấy độ bền vững kỹ thuật vượt trội khi không phụ thuộc vào một mạng xương sống tiền huấn luyện quá mạnh. Khi tiến hành huấn luyện từ đầu, hiệu suất chỉ suy giảm ở mức độ biên, trái ngược hoàn toàn với sự sụp đổ của các phương pháp tiên tiến khác trong cùng điều kiện. Điều này khẳng định cốt lõi sức mạnh của giải pháp đến từ chính tư duy thiết kế mặt nạ tinh lọc.

4.8.2 Các giả định nền tảng và những giới hạn chưa được giải quyết

Mặc dù mang lại hiệu suất khả quan, khung lý thuyết của phương pháp vẫn xoay quanh một số giả định cốt lõi và vấp phải những giới hạn nhất định trong môi trường khắc nghiệt.

Giả định về sự kế thừa và khả năng tách biệt: Nghiên cứu đặt nền móng trên giả định rằng các mô hình lớn có khả năng tổng quát hóa liên mạch không gian đặc trưng khuôn mặt cho mọi bài toán phân tích biểu cảm. Đồng thời, hệ thống tin cậy vào việc chỉ cần học được một cơ chế tạo

mặt nạ tối ưu thì năng lực chuyển giao chéo miền sẽ tự động được kích hoạt và đảm bảo độ chính xác.

Sự đánh đổi hiệu suất trên miền dữ liệu nguồn: Một bài toán chưa được giải quyết trọn vẹn là làm thế nào để dung hòa giữa việc duy trì vị trí dẫn đầu trên miền dữ liệu nguồn và khả năng mở rộng sang miền dữ liệu đích. Cấu trúc hiện tại chấp nhận một sự đánh đổi hiển nhiên: nhượng bộ độ chính xác trên dữ liệu huấn luyện cục bộ để tối đa hóa điểm số trên các tập kiểm tra chưa từng thấy.

Sự không khớp chiều không gian đặc trưng: Kiến trúc bộc lộ sự thiếu linh hoạt khi phải thay đổi cấu trúc mạng. Do đặc thù tối ưu hóa cho không gian 512 chiều, việc áp dụng các mạng có năng lực biểu diễn cao hơn đòi hỏi phải sử dụng phép toán trung bình để ép chiều. Phương pháp giảm chiều thủ công này vô tình tạo ra một điểm thắt nút, giới hạn mức trần hiệu suất mà hệ thống có thể đạt tới do thiếu vắng một cơ chế chuyển đổi đặc trưng tinh vi hơn.

Rào cản từ sự mơ hồ và dữ liệu nhiễu: Thông qua phân tích ma trận nhầm lẫn, hệ thống vẫn gặp khó khăn trong việc phân ranh giới các cảm xúc mơ hồ về ngữ nghĩa, diễn hình như trạng thái trung tính hoặc sợ hãi. Hơn nữa, với ràng buộc chỉ sử dụng một tập dữ liệu huấn luyện, mô hình trở nên cực kỳ nhạy cảm với dữ liệu có nhãn nhiễu hoặc chất lượng hiển thị thấp, cho thấy cơ chế lọc mặt nạ vẫn chưa đủ sức kháng cự trước sự sai lệch phân phối quá lớn ở đầu vào.

4.8.3 Góc nhìn cá nhân về tính thực tiễn và hiệu quả

Đánh giá một cách toàn diện, phương pháp đề xuất mang lại giá trị thực tiễn sắc bén và đại diện cho một bước chuyển mình trong phương pháp luận nghiên cứu nhận dạng cảm xúc khuôn mặt.

Về khía cạnh thực tiễn, giải pháp đã trực tiếp giải quyết rào cản lớn nhất của các phương pháp thích ứng miền truyền thống. Trong môi trường triển khai thực tế như việc cung cấp các dịch vụ API toàn cầu, việc yêu cầu thu thập trước dữ liệu người dùng để tinh chỉnh là một giả định bất khả thi về mặt kỹ thuật và quyền riêng tư. Việc hệ thống có khả năng hoạt động độc lập và ổn định trên các miền dữ liệu mù minh chứng cho độ chín muồi của thiết kế. Thêm vào đó, tính linh hoạt cao khi không kén chọn cấu trúc mạng giúp các kỹ sư dễ dàng tinh chỉnh và tích hợp vào đa dạng các hệ thống phần cứng từ biên đến đám mây.

Về phương diện hiệu quả, tư duy chấp nhận đánh đổi của phương pháp là một hướng đi khôn ngoan. Trong bối cảnh các nghiên cứu khác rơi vào vòng lặp học quá khớp cục bộ, giải pháp đã tiếp cận vấn đề từ gốc rễ. Việc mạnh dạn gỡ bỏ hoàn toàn lớp kết nối đầy đủ và khóa chặt khối đặc trưng

tổng quát là những quyết định kỹ thuật quyết liệt, mang lại sự đột phá về khả năng chống học vẹt nhần.

Dưới góc nhìn phản biện, vẫn còn đó những bài toán mở về sự phụ thuộc vào chất lượng dữ liệu môi và điểm nghẽn trong việc đồng bộ hóa không gian biểu diễn giữa các kiến trúc mạng khác nhau. Khả năng giải mã sự mơ hồ trong các trạng thái cảm xúc chuyển tiếp cũng đòi hỏi những cải tiến sâu hơn về mặt cấu trúc chú ý. Tuy nhiên, vượt lên trên những giới hạn kỹ thuật cục bộ, đóng góp lớn nhất của nghiên cứu này là việc dịch chuyển tư duy thiết kế: kéo bài toán từ việc cố gắng chiến thắng trên các bộ tiêu chuẩn đánh giá tĩnh sang việc xây dựng một hệ thống có đủ độ bền bỉ để đối mặt với sự hỗn loạn và tính bất định của dữ liệu trong thế giới thực.

4.8.4 Đề xuất hướng cải tiến và ứng dụng mở rộng

Dựa trên việc phân tích các rào cản kỹ thuật của phương pháp CAFE trong quá trình thực nghiệm, nghiên cứu đề xuất một số hướng cải tiến cấu trúc và mở rộng khả năng ứng dụng thực tiễn nhằm khắc phục các giới hạn còn tồn đọng và tối ưu hóa năng lực hệ thống.

Các hướng cải tiến kỹ thuật chuyên sâu

- **Thứ nhất**, để giải quyết sự chênh lệch chiều không gian đặc trưng, thay vì sử dụng phép toán trung bình thông qua cửa sổ trượt một cách thủ công, thiết kế có thể tích hợp một khối chuyển đổi có khả năng học. Khối này, có thể được cấu trúc dựa trên mạng nơ-ron đa tầng hoặc cơ chế chú ý chéo, đóng vai trò ánh xạ các đặc trưng không gian có số chiều lớn từ mạng xương sống xuống không gian chuẩn của mô hình ngôn ngữ - hình ảnh mà không làm biến dạng các thông tin biểu cảm vi tế. Cơ chế này sẽ khai thác triệt để sức mạnh biểu diễn của các kiến trúc mạng quy mô lớn.
- **Thứ hai**, việc phân loại các trạng thái biểu cảm mơ hồ trên ảnh tĩnh luôn tiềm ẩn sai số. Hướng tiếp cận đột phá là chuyển đổi từ nhận dạng cảm xúc khuôn mặt tĩnh sang nhận dạng cảm xúc khuôn mặt động bằng cách tích hợp các bộ thích ứng thời gian như mạng GRU hoặc LSTM để lập mô hình sự thay đổi biểu cảm qua chuỗi khung hình. Song song đó, hệ thống có thể tận dụng bộ mã hóa văn bản để kết hợp các gợi ý ngôn ngữ - hình ảnh dựa trên hệ thống đơn vị hành động cơ mặt. Việc kết hợp đa phương thức này sẽ định hướng mặt nạ hội tụ chính xác hơn vào các vùng cơ mặt đặc thù, loại bỏ sự nhập nhằng ngữ nghĩa.

- **Thứ ba**, để xử lý triệt để bài toán dữ liệu huấn luyện nhiều, kiến trúc có thể được nâng cấp bằng phương pháp học bán giám sát. Cơ chế này nhằm tận dụng các tập dữ liệu nhận dạng khuôn mặt quy mô khổng lồ chưa được gán nhãn biểu cảm. Trong quy trình này, một mạng giáo viên được huấn luyện trên tập dữ liệu có nhãn chuẩn sẽ khởi tạo các nhãn giả, từ đó hướng dẫn mạng học sinh trích xuất và tinh lọc đặc trưng từ kho dữ liệu chưa gán nhãn, giúp hệ thống tự tăng cường khả năng kháng nhiễu một cách chủ động.
- **Thứ tư**, nhằm giải quyết sự đánh đổi hiệu suất trên miền dữ liệu nguồn, một kiến trúc nhánh kép có thể được thiết lập. Một nhánh duy trì lớp kết nối đầy đủ nhằm tối ưu hóa sâu các đặc trưng cục bộ cho miền gốc, trong khi nhánh thứ hai tiếp tục duy trì cơ chế mặt nạ để bảo toàn năng lực thích ứng chéo miền. Quyết định dự đoán cuối cùng được dung hợp thông qua cơ chế học tự điều chỉnh trọng số dựa trên độ tin cậy của từng phân nhánh đối với mẫu dữ liệu đầu vào.

Tiềm năng ứng dụng thay thế trong môi trường thực tiễn

Triết lý thiết kế mô phỏng nhận thức tự nhiên và cấu trúc tinh gọn của phương pháp không chỉ giới hạn trong môi trường học thuật mà còn đặc biệt phù hợp cho các bài toán công nghiệp phức tạp:

- **Trong các hệ thống giám sát người lái xe:** Môi trường cabin thường xuyên chịu sự biến động về ánh sáng, rung lắc và góc quan sát. Việc mô hình có khả năng trích xuất đặc trưng biểu cảm độc lập với bối cảnh biến nó thành giải pháp lý tưởng để nhận diện trạng thái mệt mỏi, tức giận hay phân tâm của tài xế theo thời gian thực. Hệ thống có thể vận hành ổn định mà không đòi hỏi quá trình thu thập và huấn luyện lại dữ liệu cho từng loại camera chuyên biệt.
- **Đối với lĩnh vực tương tác người - máy:** Đặc biệt là rô-bốt hỗ trợ y tế hoặc các trợ lý ảo, yêu cầu thấu hiểu cảm xúc người dùng để đưa ra phản hồi thấu cảm là yếu tố sống còn. Khả năng tổng quát hóa zero-shot của phương pháp cho phép rô-bốt hoạt động mượt mà và tương thích tức thời khi tiếp xúc với những người dùng mới ngoài đời thực, loại bỏ hoàn toàn yêu cầu về quá trình hiệu chỉnh cá nhân hóa.
- **Công cụ phân tích độc lập đánh giá thiên lệch văn hóa:** Do các mô hình ngôn ngữ - hình ảnh lớn thường chứa đựng nội dung thiên lệch phương Tây, giải pháp này có thể được

nhúng vào các mô hình hóa dựa trên tác tử để đo lường và định lượng sự bất đối xứng trong việc nhận dạng biểu cảm đa văn hóa, góp phần xây dựng các hệ thống trí tuệ nhân tạo công bằng và minh bạch hơn.

5 Demo minh họa và thực nghiệm

5.1 Mục tiêu thực nghiệm

Phần thực nghiệm được xây dựng nhằm kiểm chứng khả năng chạy lại phương pháp CAFE trong bài báo *Generalizable Facial Expression Recognition*, đồng thời đánh giá mức độ tổng quát hóa của mô hình khi huấn luyện trên một miền dữ liệu nguồn và suy luận trực tiếp trên các miền dữ liệu chưa từng được dùng trong huấn luyện. Cụ thể, nhóm đặt ra ba mục tiêu chính.

Thứ nhất, nhóm tái hiện quy trình huấn luyện CAFE trên RAF-DB, sử dụng mã nguồn chính thức đã được điều chỉnh tối thiểu để phù hợp với môi trường chạy Kaggle. Kết quả huấn luyện được lưu dưới dạng checkpoint `ours_best.pth`, `ours_final.pth` và nhật ký độ chính xác theo từng epoch. Thứ hai, nhóm xây dựng demo suy luận cho bài toán nhận dạng cảm xúc khuôn mặt tĩnh. Demo nhận đầu vào là ảnh khuôn mặt hoặc một thư mục ảnh có nhãn, sau đó trả về nhãn dự đoán thuộc bảy lớp cảm xúc: *surprise*, *fear*, *disgust*, *happy*, *sadness*, *anger* và *neutral*. Ngoài nhãn dự đoán, hệ thống còn xuất điểm tin cậy, file dự đoán chi tiết và ma trận nhầm lẫn để phục vụ phân tích.

Thứ ba, nhóm mở rộng đánh giá chéo miền trên nhiều bộ dữ liệu khác nhau, bao gồm FERPlus, AffectNet, SFEW2.0, MMAFEDB và CK+48. Các bộ dữ liệu này có điều kiện thu thập, độ phân giải, phân phối lớp và quy ước nhãn khác nhau, do đó phù hợp để kiểm tra giả thuyết cốt lõi của CAFE: mô hình không chỉ cần đạt độ chính xác cao trên tập kiểm thử cùng miền, mà còn phải duy trì hiệu quả khi gặp dữ liệu ngoài miền.

5.2 Phân tích kỹ thuật từ mã nguồn

Mã nguồn của repository **Generalizable-FER** hiện thực ý tưởng chính của phương pháp CAFE theo hướng kết hợp đặc trưng tổng quát của CLIP với một cơ chế chọn lọc đặc trưng theo biểu cảm. Thay vì huấn luyện toàn bộ bộ trích xuất đặc trưng từ đầu trên một tập FER cụ thể, mô hình giữ cố định CLIP ViT-B/32 để lấy biểu diễn ảnh có tính khái quát, sau đó dùng ResNet-18 để sinh mask theo từng ảnh đầu vào. Mask này được đưa qua sigmoid và nhân với feature của CLIP nhằm giữ lại các kênh liên quan đến biểu cảm khuôn mặt, đồng thời giảm ảnh hưởng của các thông tin dễ gây lệch miền như danh tính, nền ảnh, pose hoặc chất lượng ảnh.

Cấu trúc mã nguồn và các tập tin quan trọng.

Phần hiện thực cốt lõi nằm trong file `code/ours_CAFE.py`. File này bao gồm định nghĩa dataset `RafDataset`, kiến trúc ResNet-18 dùng làm mask generator, lớp `Model`, các hàm phụ cho channel separation và channel dropping, cùng vòng lặp huấn luyện và đánh giá. Thư mục `code/clip/` chứa phần cài đặt CLIP được gọi bởi `clip.load("ViT-B/32")`. Ngoài ra, các notebook trong `code/evaluation_results_demo_trained_on_FERPlus/` phục vụ minh họa đánh giá, còn các hình trong `assets/` hỗ trợ mô tả framework và kết quả.

Luồng xử lý chính của mô hình.

Trong `Model.forward()`, ảnh đầu vào x được đưa qua hai nhánh song song. Nhánh thứ nhất dùng CLIP để trích xuất feature ảnh:

```
1 with torch.no_grad():
2     image_features = clip_model.encode_image(x)
```

Việc đặt `encode_image()` trong `torch.no_grad()` cho thấy CLIP không được cập nhật trọng số trong quá trình train. Đây là lựa chọn quan trọng đối với bài toán generalizable FER, vì CLIP đã được pretrain trên dữ liệu lớn và có biểu diễn tổng quát hơn so với một backbone chỉ học trên dataset nguồn như RAF-DB.

Nhánh thứ hai dùng ResNet-18 để tạo vector 512 chiều từ cùng ảnh đầu vào. Vector này không được dùng trực tiếp làm logits phân loại, mà đóng vai trò mask thô. Vì CLIP ViT-B/32 cũng trả về feature 512 chiều, hai vector có thể được nhân từng kênh:

```
1 x = image_features * torch.sigmoid(x)
2 out = self.fc(x)
```

Cơ chế này có thể tóm tắt bằng công thức:

$$F = \text{CLIP}(x), \quad M = \text{ResNet18}(x), \quad \tilde{F} = F \odot \sigma(M), \quad \hat{y} = \text{FC}(\tilde{F}).$$

Trong đó, F là feature tổng quát từ CLIP, M là mask do ResNet-18 sinh ra, $\sigma(M)$ là mask mềm trong khoảng $[0, 1]$, $\tilde{F}$ là feature đã được chọn lọc theo biểu cảm, và $\hat{y}$ là logits của 7 lớp cảm xúc.

Vai trò của sigmoid mask.

Sigmoid là thành phần then chốt vì nó biến output của ResNet-18 thành một bộ lọc mềm theo

kênh. Giá trị gần 1 nghĩa là kênh CLIP tương ứng được giữ lại nhiều, còn giá trị gần 0 nghĩa là kênh đó bị giảm ảnh hưởng. Nhờ giới hạn mask trong khoảng $[0, 1]$, mô hình không đảo dấu hoặc khuếch đại tùy ý feature CLIP. Nếu bỏ sigmoid và nhân trực tiếp với output ResNet, mask có thể nhận giá trị âm hoặc quá lớn, làm biến dạng biểu diễn tổng quát của CLIP và tăng nguy cơ overfit vào miền dữ liệu nguồn.

Classifier và các hàm mất mát phụ.

Sau khi có masked feature, source dùng một fully connected layer `nn.Linear(512, 7)` để dự đoán 7 lớp biểu cảm. Loss chính là cross entropy giữa output này và nhãn thật. Bên cạnh đó, trong pha train, hàm `supervisor()` tạo thêm hai loss phụ: channel separation loss và channel-diverse loss. Source gom feature 512 chiều thành các nhóm kênh, dùng `my_MaxPool2d(..., cnum=73)` để lấy phản hồi mạnh nhất theo nhóm, rồi tính cross entropy phụ với nhãn. Cơ chế này ép feature sau mask không chỉ đúng qua FC classifier, mà còn có cấu trúc phân biệt theo từng nhóm cảm xúc. Channel dropping được hiện thực trong hàm `Mask(nb_batch)`. Hàm này tạo mask nhị phân để random drop một số kênh trong từng nhóm khi train. Mục tiêu là tránh việc mô hình phụ thuộc vào một vài kênh mạnh cố định; thay vào đó, thông tin biểu cảm phải được phân bố ổn định hơn trên nhiều kênh. Tổng loss trong vòng lặp train được tính như sau:

```
1 loss1 = nn.CrossEntropyLoss()(output, labels)
2 loss = loss1 + 5 * MC_loss[1] + 1.5 * MC_loss[0]
```

Trong đó, `loss1` là classification loss chính, `MC_loss[0]` là channel separation loss, còn `MC_loss[1]` là channel-diverse loss. Hai hệ số 1.5 và 5 đóng vai trò cân bằng giữa mục tiêu phân loại và các ràng buộc regularization trên feature.

Tiền xử lý dữ liệu và quy trình huấn luyện.

`RafDataset` đọc nhãn từ thư mục `EmoLabel`, lấy ảnh đã căn chỉnh từ `Image/aligned`, sau đó đưa label về miền $[0, 6]$ tương ứng với 7 lớp cảm xúc. Trong huấn luyện, ảnh được resize về 224×224 , chuyển sang tensor, normalize theo mean/std ImageNet, đồng thời có augmentation như horizontal flip, Gaussian noise và random erasing. Khi đánh giá, source vẫn resize và normalize nhưng bỏ các augmentation ngẫu nhiên. Quy trình train dùng Adam với learning rate 2×10^{-4} , weight decay 10^{-4} , scheduler ExponentialLR và lưu checkpoint `ours_best.pth` khi accuracy tốt hơn.

Suy luận và khác biệt giữa train/test.

Ở pha test, `Model.forward()` không gọi `supervisor()` và không dùng channel dropping. Mô hình chỉ tính feature CLIP, sinh sigmoid mask bằng ResNet-18, nhân hai feature lại với nhau, rồi đưa qua FC classifier để lấy dự đoán cuối cùng. Điều này hợp lý vì channel separation, channel dropping và channel-diverse loss chỉ có nhiệm vụ định hướng quá trình học representation; khi suy luận, việc giữ các yếu tố ngẫu nhiên như dropping có thể làm output kém ổn định.

Tác động nếu thay đổi hoặc loại bỏ thành phần quan trọng.

Nếu bỏ CLIP cố định, mô hình mất nền tảng feature tổng quát và dễ trở thành một FER backbone thông thường, có nguy cơ học các đặc trưng riêng của dataset nguồn. Nếu fine-tune CLIP trực tiếp, accuracy trên source domain có thể tăng nhưng khả năng tổng quát sang dataset khác có thể giảm do domain overfitting. Nếu bỏ ResNet-18 mask generator hoặc phép nhân `image_features * torch.sigmoid(x)`, mô hình gần như chỉ còn CLIP cộng classifier, không còn cơ chế chọn lọc kênh theo từng ảnh đầu vào. Nếu bỏ các loss phụ trong `supervisor()`, mô hình vẫn train được bằng cross entropy chính, nhưng feature sau mask thiếu ràng buộc class-wise và có thể phụ thuộc nhiều hơn vào FC classifier.

Nhìn chung, điểm cốt lõi của source code không chỉ là “dùng CLIP”, mà là dùng CLIP ở trạng thái cố định và học một sigmoid mask để chọn ra phần feature liên quan đến biểu cảm. ResNet-18 đảm nhiệm việc sinh mask thích ứng theo ảnh, FC classifier tạo output cuối cùng, còn channel separation, channel dropping và channel-diverse loss đóng vai trò regularization giúp feature có cấu trúc hơn. Sự kết hợp này giải thích vì sao CAFE hướng tới mục tiêu tổng quát hóa tốt hơn so với cách huấn luyện end-to-end truyền thống trên một tập FER đơn lẻ.

5.3 Thiết lập thực nghiệm

Bảng 4 tóm tắt cấu hình thực nghiệm chính. RAF-DB được dùng làm bộ dữ liệu nguồn để huấn luyện. Sau đó, checkpoint tốt nhất được đánh giá trực tiếp trên các bộ dữ liệu khác mà không tinh chỉnh lại, đúng với tinh thần đánh giá zero-shot cross-dataset của bài báo.

Trong số các bộ dữ liệu được sử dụng để đánh giá chéo miền, tập dữ liệu mở rộng CK+48 là một trường hợp đặc biệt được thu thập trong điều kiện phòng thí nghiệm. Khác với các tập dữ liệu tự nhiên (in-the-wild), tiến trình ghi nhận biểu cảm của CK+48 bắt đầu từ trạng thái trung tính (*neutral*) cho đến khi biểu cảm đạt đỉnh điểm (*peak*). Để phân tích sâu sắc ảnh hưởng của cấu trúc

Bảng 4: Thiết lập thực nghiệm


Thành phần	Mô tả
Bộ dữ liệu huấn luyện	RAF-DB, sử dụng bảy lớp cảm xúc theo thứ tự: surprise, fear, disgust, happy, sadness, anger, neutral.
Bộ dữ liệu đánh giá	RAF-DB test, FERPlus test, AffectNet Test, SFEW2.0 Val, MMAFEDB test và CK+48. Các lớp contempt bị loại bỏ vì mô hình không có đầu ra tương ứng.
Phần cứng	Kaggle Notebook có GPU, sử dụng thiết bị <code>cuda:0</code> trong quá trình huấn luyện và đánh giá.
Phần mềm	Python, PyTorch, torchvision, OpenCV, PIL, NumPy, pandas, scikit-learn, matplotlib, seaborn và CLIP ViT-B/32.
Tiền xử lý	Chuyển ảnh sang RGB, resize về 224×224 , chuẩn hóa theo ImageNet. Với CK+48, ảnh 48×48 được phóng lên 224×224 .
Siêu tham số huấn luyện	60 epoch, batch size 32, Adam, learning rate 0.0002, weight decay 10^{-4} , ExponentialLR $\gamma = 0.9$, seed 3407.
Giao thức đánh giá	Không tinh chỉnh trên miền đích; đo Overall Accuracy, Mean Accuracy, Macro-F1, độ chính xác từng lớp và ma trận nhầm lẫn.

dữ liệu đối với mô hình GFER, nhóm đã thiết lập đánh giá CK+48 trên hai chế độ riêng biệt:


- CK+48 7 lớp (gồm Neutral):** Đánh giá trên toàn bộ tiến trình biểu cảm bao gồm cả trạng thái trung tính. Như thể hiện ở Hình 2, chế độ này có sự mất cân bằng dữ liệu cực kỳ lớn với lớp trung tính chiếm ưu thế tuyệt đối (593 trên tổng số 902 mẫu), trong khi các lớp khó như sợ hãi (*fear*) chỉ có 25 mẫu.
- CK+48 6 lớp peak-only:** Loại bỏ hoàn toàn lớp trung tính và chỉ đánh giá trên các mẫu ảnh biểu cảm đạt đỉnh. Chế độ này (Hình 3) giúp phân phối giữa các cảm xúc cân bằng hơn, nhưng tổng số mẫu kiểm thử giảm mạnh xuống còn 309 mẫu.

5.4 Kết quả thực nghiệm

Trên RAF-DB, mô hình đạt độ chính xác tốt nhất 89.15% tại epoch 41 và lặp lại mức này tại epoch 57. Độ chính xác tăng nhanh trong 10 epoch đầu, từ 69.10% lên 87.91%, sau đó hội tụ quanh vùng 88.8–89.1%. Kết quả này cho thấy quá trình huấn luyện ổn định và checkpoint cuối không bị suy giảm mạnh so với checkpoint tốt nhất; tại epoch 60, độ chính xác đạt 88.92%.



Hình 2: Phân phối mẫu CK+48 ở chế độ 7 lớp (gồm Neutral).



Hình 3: Phân phối mẫu CK+48 ở chế độ 6 lớp peak-only.

Hình 4: So sánh phân phối số lượng mẫu của bộ dữ liệu CK+48 ở hai chế độ đánh giá.

Bảng 5 so sánh kết quả của nhóm với các giá trị được báo cáo trong bài báo gốc đối với thiết lập huấn luyện trên RAF-DB. Nhìn chung, kết quả tái hiện trên RAF-DB cao hơn nhẹ so với bài báo gốc. Trên MMAFEDB, kết quả gần như tương đương. Trên AffectNet, kết quả của nhóm cao hơn giá trị tham chiếu. Tuy nhiên, trên FERPlus và SFEW2.0, độ chính xác thấp hơn bài báo, phản ánh ảnh hưởng của khác biệt dữ liệu, cấu trúc thư mục, tiền xử lý và điều kiện chạy lại.

Bảng 5: So sánh kết quả thực nghiệm với bài báo gốc

Tập đánh giá	Bài báo gốc OA (%)	Nhóm thực nghiệm OA (%)	Sai khác
RAF-DB	88.72	89.15	+0.43
FERPlus	73.16	66.81	-6.35
AffectNet	45.86	52.01	+6.15
SFEW2.0	52.86	46.87	-5.99
MMAFEDB	56.80	56.72	-0.08
Trung bình	63.48	62.31	-1.17

Bên cạnh Overall Accuracy, nhóm tính thêm Mean Accuracy và Macro-F1 để đánh giá cân bằng hơn trong bối cảnh dữ liệu mất cân bằng lớp. Bảng 6 trình bày kết quả chi tiết. FERPlus đạt 66.81% OA, 56.24% MA và 53.06% Macro-F1. AffectNet đạt 52.01% OA, 46.93% MA và 43.97% Macro-F1. MMAFEDB đạt 56.72% OA, gần sát kết quả bài báo gốc, nhưng MA chỉ đạt 42.95%, cho thấy mô hình vẫn thiên về các lớp có số lượng mẫu lớn. SFEW2.0 là tập khó nhất trong thí nghiệm, chỉ đạt 46.87% OA và 33.98% Macro-F1 do ảnh hưởng trong môi trường phim có nhiều biến thiên về ánh sáng, góc mặt và che khuất.

Bảng 6: Kết quả đánh giá chéo miền và mở rộng

Tập dữ liệu	Số mẫu	OA (%)	MA (%)	Macro-F1 (%)
CK+48, 6 lớp peak-only	309	64.72	52.26	51.43
CK+48, 7 lớp có neutral	902	82.48	57.90	53.73
FERPlus test	3543	66.81	56.24	53.06
AffectNet Test	13206	52.01	46.93	43.97
SFEW2.0 Val	431	46.87	38.78	33.98
MMAFEDB test	17356	56.72	42.95	43.17

Kết quả theo từng lớp cho thấy mô hình nhận dạng tốt nhất các biểu cảm có dấu hiệu hình học rõ ràng. Trên CK+48, lớp *happy* đạt 100%, *surprise* đạt 95.18% và *neutral* đạt 91.74%. Trên FERPlus, lớp *happy* đạt 94.51%, trong khi *surprise* và *sadness* lần lượt đạt 68.22% và 67.93%. Ngược lại, các lớp *fear*, *disgust* và *anger* thường có độ chính xác thấp hơn, đặc biệt *fear* đạt 0% trên CK+48 và SFEW2.0. Điều này phù hợp với ma trận nhầm lẫn thu được: các cảm xúc có biểu hiện thị giác gần nhau hoặc có ít mẫu dễ bị dự đoán nhầm sang *happy*, *sadness* hoặc *neutral*.

5.5 Phân tích sai khác và thảo luận

Sai khác giữa kết quả của nhóm và bài báo gốc đến từ nhiều nguyên nhân. Trước hết, mặc dù nhóm sử dụng cùng ý tưởng huấn luyện trên RAF-DB và đánh giá chéo miền, môi trường chạy lại không hoàn toàn trùng khớp với thiết lập gốc của tác giả. Các yếu tố như phiên bản thư viện, GPU, cách tải checkpoint CLIP, seed, batch size và chiến lược đọc dữ liệu đều có thể tạo sai khác nhỏ trong quá trình tối ưu.

Thứ hai, các bộ dữ liệu được lấy từ nguồn Kaggle có cấu trúc thư mục và quy ước nhãn không đồng nhất. FERPlus có thư mục *contempt* bị loại bỏ; AffectNet cũng bỏ lớp *Contempt*; SFEW2.0 sử dụng tập Val vì tập Test không có nhãn trong cấu trúc dữ liệu hiện có. Những điều chỉnh này cần thiết để ánh xạ về bảy lớp của CAFE, nhưng đồng thời làm giao thức đánh giá khác một phần so với bài báo.

Thứ ba, CK+48 là một trường hợp mở rộng ngoài các tập chính trong bài báo. Ảnh CK+48 có độ phân giải 48×48 , sau đó được phóng lên 224×224 để phù hợp với đầu vào của mô hình. Quá trình phóng đại này không tạo thêm chi tiết khuôn mặt mới, nên các đặc trưng vi mô của những cảm xúc khó như *fear* hoặc *anger* có thể bị mất hoặc không đủ rõ. Điều này lý giải vì sao độ chính

xác tổng thể của CK+48 có neutral khá cao, nhưng Mean Accuracy và Macro-F1 thấp hơn nhiều: mô hình làm tốt ở các lớp dễ và đông mẫu, nhưng yếu ở các lớp khó.

Thứ tư, phân phối lớp giữa các bộ dữ liệu mất cân bằng rõ rệt. Minh chứng rõ nét nhất là ở bộ dữ liệu mở rộng CK+48 đã được nhóm phân tích trực quan qua biểu đồ phân phối mẫu tại Hình 4 (Mục 5.3 / 5.4). Sự mất cân bằng cực đoan này giải thích lý do vì sao ở chế độ 7 lớp, Overall Accuracy đạt mức rất cao (82.48%), nhưng Mean Accuracy và Macro-F1 lại thấp hơn nhiều (57.90% và 53.73%), do mô hình nhận diện tốt lớp chiếm đa số (*neutral*, *happy*) nhưng đoán sai các lớp ít mẫu như *fear* hay *anger*. Khi chuyển sang chế độ 6 lớp peak-only, việc loại bỏ hoàn toàn lớp *neutral* giúp phản ánh thực chất và công bằng hơn năng lực nhận dạng cảm xúc thực tế của mô hình.

Từ các kết quả trên, có thể nhận xét rằng CAFE giữ được năng lực tổng quát hóa tương đối tốt khi chuyển từ RAF-DB sang các bộ dữ liệu ngoài miền. Tuy nhiên, mô hình vẫn chưa giải quyết triệt để các lớp cảm xúc mơ hồ, các bộ dữ liệu có ảnh chất lượng thấp hoặc các trường hợp phân phối lớp lệch mạnh. Do đó, trong báo cáo này, Overall Accuracy được dùng để so sánh với bài báo gốc, còn Mean Accuracy và Macro-F1 được dùng để phân tích sâu hơn về tính cân bằng của mô hình.

5.6 Mở rộng hoặc cải tiến

Ngoài việc chạy lại huấn luyện và đánh giá trên các bộ dữ liệu được đề cập trong bài báo, nhóm thực hiện thêm hai mở rộng. Mở rộng thứ nhất là xây dựng script đánh giá CK+48. Đây là bộ dữ liệu có đặc điểm khác biệt so với RAF-DB và các tập dữ liệu in-the-wild vì ảnh có độ phân giải thấp, nhiều mẫu được thu trong điều kiện phòng thí nghiệm và có thể bao gồm cả mẫu trung tính. Việc đánh giá trên hai chế độ CK+48, gồm 6 lớp peak-only và 7 lớp có neutral, giúp quan sát rõ ảnh hưởng của cách chọn mẫu và ánh xạ nhãn đến kết quả.

Mở rộng thứ hai là chuẩn hóa pipeline đánh giá chéo miền cho nhiều bộ dữ liệu thư mục. Script `evaluate_cross_dataset.py` tự động nhận diện split, bỏ lớp *contempt* khi cần, ánh xạ tên lớp về thứ tự nhãn của CAFE và lưu đồng nhất các file `predictions.csv`, `metrics.json` và `confusion_matrix.png`. Nhờ đó, quá trình so sánh giữa FERPlus, AffectNet, SFEW2.0 và MMAFEDB trở nên nhất quán hơn và dễ kiểm tra lại.

Trong các hướng cải tiến tiếp theo, nhóm đề xuất bổ sung cơ chế cân bằng lớp khi đánh giá và huấn luyện, chẳng hạn weighted loss hoặc balanced sampler, để giảm thiên lệch về các lớp phổ biến như *happy* và *neutral*. Ngoài ra, có thể kết hợp thêm dữ liệu khuôn mặt độ phân giải thấp hoặc

chiến lược tăng cường dữ liệu mô phỏng nhiều, mờ, lệch sáng để cải thiện hiệu quả trên CK+48 và SFEW2.0. Cuối cùng, nếu mở rộng sang video, việc bổ sung mô-đun thời gian như GRU hoặc Transformer temporal adapter có thể giúp mô hình phân biệt tốt hơn các cảm xúc dễ nhầm lẫn trên ảnh tĩnh.

5.7 Demo minh họa

Dự án cung cấp hai ứng dụng demo webcam theo thời gian thực cho nhận dạng biểu cảm khuôn mặt. Demo thứ nhất sử dụng mô hình CAFE đã được huấn luyện kết hợp CLIP ViT-B/32 và ResNet-18 để nhận dạng bảy loại biểu cảm (surprise, fear, disgust, happy, sadness, anger, neutral). Demo thứ hai không cần checkpoint mà sử dụng CLIP pure zero-shot với multiple text prompts. Cả hai demo đều thực hiện quy trình: phát hiện khuôn mặt từ webcam, cắt vùng khuôn mặt, tiền xử lý ảnh, dự đoán biểu cảm, và hiển thị kết quả trực tiếp lên frame video.

- **Đầu vào:** webcam.
- **Đầu ra:** Nhận dự đoán, quyết định xác minh.
- **Thư viện/công cụ:** PyTorch, OpenCV, pillow, scikit-learn, ftfy, ...
- **Kịch bản chạy:** Chạy source code demo và thực hiện thay đổi các biểu cảm trên khuôn mặt.
- **Link video:** [Video demo CLIP + CAFE](#).
- **source code demo:** [Source code demo](#)

6 Đánh giá, phân công và kết luận

6.1 Đánh giá phương pháp

Phương pháp CAFE (Cognition of humAn for Facial Expression) đã thể hiện những ưu điểm vượt trội về mặt lý thuyết lẫn thực nghiệm trong bài toán nhận dạng cảm xúc khuôn mặt có khả năng tổng quát hóa cao (Generalizable FER). Qua quá trình nghiên cứu và thực nghiệm tái hiện kết quả, nhóm đưa ra các đánh giá kỹ thuật trọng tâm sau:

- **Cơ chế phân tách đặc trưng thông minh:** Bằng cách đóng băng toàn bộ trọng số của mô hình ngôn ngữ - hình ảnh lớn CLIP ($ViT - B/32$), phương pháp đã tận dụng được không gian biểu diễn khuôn mặt cực kỳ tổng quát được học từ hàng triệu ảnh Internet. Việc này giúp mô hình hoàn toàn miễn nhiễm với hiện tượng học quá khớp (overfitting) các đặc trưng nhiễu cục bộ của tập dữ liệu nguồn như điều kiện ánh sáng, pose mặt hay đặc trưng danh tính cá nhân.
- **Mặt nạ Sigmoid thích ứng hiệu quả:** Việc sử dụng mạng ResNet-18 gọn nhẹ làm bộ tạo mặt nạ $M_s = \text{Sigmoid}(M)$ cho phép mô hình học cách tinh lọc động các kênh đặc trưng liên quan đến cảm xúc cho từng ảnh đầu vào. Cơ chế này hoạt động như một bộ lọc xác suất mềm, giữ nguyên các thông tin hữu ích và triệt tiêu các kênh dư thừa của CLIP mà không làm biến dạng cấu trúc đặc trưng gốc.
- **Thiết kế bộ phân loại không phụ thuộc lớp liên kết đầy đủ (FC):** Đây là một cải tiến táo bạo nhằm loại bỏ hoàn toàn tầng FC ở phần cuối mạng — vốn là tác nhân chính gây ra việc ghi nhớ nhiễu cục bộ. Việc chia cắt trực tiếp khối đặc trưng đã lọc $\tilde{F}$ thành $L = 7$ phần dọc theo chiều kênh và áp dụng phép toán gộp cực đại (max pooling) giúp mô hình tối ưu hóa trực tiếp trên ranh giới quyết định của từng lớp cảm xúc.
- **Độ bền bỉ và tính hội tụ cao:** Hàm mất mát đa nhiệm kết hợp tuyến tính $l_{train} = l_{cls} + \lambda l_{sep} + \beta l_{div}$ giúp ràng buộc chặt chẽ tính phân tách kênh (l_{sep}) và tính đa dạng kênh (l_{div}). Kết quả thực nghiệm của nhóm trên tập RAF-DB đạt độ chính xác 89.15% (vượt 0.43% so với bài báo gốc) và kết quả đánh giá chéo trên AffectNet đạt 52.01% (vượt 6.15% so với tham chiếu) đã chứng minh độ bền bỉ vượt trội của phương pháp ngay cả khi thay đổi cấu trúc mạng xương sống.

6.2 Hạn chế và vấn đề chưa giải quyết

Mặc dù đạt được những kết quả khả quan về khả năng tổng quát hóa zero-shot, thực nghiệm chi tiết của nhóm trên các tập dữ liệu ngoài miền (out-of-domain) đã chỉ ra một số hạn chế cốt lõi sau:

- **Sự sụt giảm nghiêm trọng hiệu suất trên các lớp ít mẫu (Class Imbalance):** Phân tích ma trận nhầm lẫn trên các tập dữ liệu như CK+48, FERPlus, và SFEW2.0 cho thấy mô hình bị thiên lệch nặng nề về các lớp chiếm đa số như *happy* và *neutral*. Ngược lại, các lớp cảm xúc có tần suất xuất hiện thấp và có biểu hiện cơ mặt phức tạp như *fear* (sợ hãi), *disgust* (ghê tởm) có độ chính xác cực kỳ thấp, thậm chí đạt 0% trên tập CK+48 và SFEW2.0. Hàm mất mát hiện tại chưa có cơ chế trọng số để bù trừ sự mất cân bằng này.
- **Nhạy cảm với chất lượng và độ phân giải hình ảnh:** Đối với tập dữ liệu CK+48, do ảnh gốc có độ phân giải rất thấp (48×48 pixel) nên khi phóng đại lên 224×224 để phù hợp đầu vào mô hình, các đặc trưng hình học và biểu cảm cơ mặt vi tế đã bị mờ nhòe. Do CLIP được huấn luyện trên ảnh chất lượng cao, sự không khớp về chất lượng ảnh khiến mặt nạ Sigmoid khó định vị chính xác vùng đặc trưng cảm xúc.
- **Giới hạn của thông tin ảnh tĩnh (Static FER):** Mô hình CAFE chỉ xử lý thông tin trên từng khung ảnh độc lập. Trong thực tế, các biểu cảm khuôn mặt mang tính động và diễn tiến theo thời gian. Việc thiếu đi ngữ cảnh thời gian khiến mô hình dễ nhầm lẫn giữa các trạng thái cảm xúc chuyển tiếp hoặc mơ hồ về mặt ngữ nghĩa (ví dụ giữa *sadness* và *neutral*, hoặc *fear* và *surprise*).
- **Sự phụ thuộc vào phân phối nhãn nguồn:** Mô hình được huấn luyện trên nhãn cứng của RAF-DB vốn được gán bởi các chuyên gia dựa trên phân phối chuẩn. Khi chuyển sang các tập dữ liệu có quy ước gán nhãn khác (như FERPlus sử dụng cơ chế bỏ phiếu đám đông để tạo nhãn phân phối), sự sai lệch trong định nghĩa biên cảm xúc làm giảm độ chính xác tổng thể.

6.3 Nhận định cá nhân và hướng phát triển

Từ góc nhìn của những người thực hiện đồ án, nhóm nhận thấy phương pháp CAFE đã mở ra một tư duy thiết kế rất thực tiễn cho các ứng dụng nhận dạng cảm xúc trong thế giới thực. Việc loại

bỏ hoàn toàn yêu cầu thu thập dữ liệu miền đích giúp mô hình dễ dàng tích hợp trực tiếp vào các API thương mại hoặc các hệ thống nhúng (như camera giám sát người lái xe) mà không lo ngại về vấn đề quyền riêng tư dữ liệu hay chi phí tính chỉnh lại mạng.

Để khắc phục các hạn chế hiện hữu và nâng cao hơn nữa hiệu suất của hệ thống, nhóm đề xuất một số hướng phát triển và cải tiến kỹ thuật tiềm năng trong tương lai:

1. **Tích hợp hàm mất mát cân bằng lớp (Class-Balanced Loss):** Thay thế hàm Cross-Entropy thông thường bằng Focal Loss hoặc Cost-Sensitive Loss kết hợp với bộ lấy mẫu cân bằng (Balanced Sampler) trong quá trình huấn luyện trên RAF-DB. Điều này sẽ ép buộc mô hình tập trung học các đặc trưng của các lớp thiểu số như *fear* và *disgust*, nâng cao chỉ số Mean Accuracy và Macro-F1.
2. **Đào tạo đa độ phân giải thích ứng (Multi-resolution Training):** Tăng cường dữ liệu huấn luyện bằng cách làm mờ (blur) hoặc hạ độ phân giải ngẫu nhiên của tập RAF-DB để mô hình học được các đặc trưng bất biến với chất lượng hình ảnh, từ đó cải thiện hiệu suất kiểm thử trên các tập ảnh chất lượng thấp như CK+48.
3. **Mở rộng sang nhận dạng biểu cảm động (Video-based FER):** Phát triển mô-đun temporal adapter dựa trên cấu trúc mạng hồi quy GRU, LSTM hoặc mạng tự chú ý Transformer đặt phía sau khối đặc trưng $\tilde{F}$. Sự bổ sung này sẽ giúp mô hình bắt giữ được sự thay đổi cơ mặt theo thời gian, giải quyết triệt để sự mơ hồ giữa các lớp cảm xúc tĩnh.
4. **Hướng dẫn mặt nạ bằng gợi ý văn bản cấu trúc (Text-guided Masking):** Tận dụng bộ mã hóa văn bản (Text Encoder) của CLIP để đưa vào các mô tả chi tiết về Đơn vị hành động cơ mặt (Action Units — FACS) tương ứng với từng loại cảm xúc. Việc kết hợp thông tin đa phương thức (multi-modal prompting) này hứa hẹn sẽ định hướng mặt nạ Sigmoid hội tụ vào các vùng cơ mặt đích một cách chính xác và tường minh hơn.

6.4 Kế hoạch và phân công nhiệm vụ

Bảng 7: Phân công nhiệm vụ và tỷ lệ hoàn thành

MSSV	Thành viên	Nhiệm vụ phụ trách	Tỷ lệ hoàn thành
22120134	Hoàng Tiến Huy	Tìm hiểu mã nguồn của phương pháp SOTA, phân tích cơ sở thiết kế của hệ thống và triển khai demo nhận diện cảm xúc theo thời gian thực bằng webcam.	100%
23120195	Lê Hà Thanh Chương	Khảo sát một bài báo SOTA về nhận diện cảm xúc, phân tích động lực nghiên cứu, ý tưởng cốt lõi, điểm khác biệt so với giáo trình và đưa ra nhận xét cá nhân.	100%
23120232	Lê Thượng Đế	Nghiên cứu nội dung Facial Expression trong giáo trình, hệ thống hóa nền tảng lý thuyết, quy trình xử lý và các công thức toán học liên quan.	100%
23120245	Nguyễn Quang Duy	Tổng hợp nội dung và kết quả của nhóm, rà soát tính thống nhất của báo cáo, xây dựng slide trình bày và chuẩn bị kịch bản thuyết trình.	100%
23120258	Lưu Trọng Hiếu	Ghi nhận kết quả thực nghiệm từ mã nguồn, đối chiếu với kết quả trong bài báo, phân tích nguyên nhân sai lệch và hoàn thiện phần nhận xét thực nghiệm.	100%
23120260	Văn Đình Hiếu	Cài đặt môi trường thực nghiệm, chạy lại mã nguồn của bài báo và thực hiện thêm thử nghiệm trên dataset ngoài để đánh giá khả năng tổng quát của mô hình.	100%

6.5 Kết luận

Đồ án môn học “Nhận dạng mẫu” với chủ đề Nhận dạng cảm xúc khuôn mặt có khả năng tổng quát hóa cao (Generalizable FER) đã hoàn thành trọn vẹn tất cả các mục tiêu đề ra ban đầu trên cả hai phương diện nghiên cứu lý thuyết và thực hành thực nghiệm. Thông qua quá trình triển khai dự án, nhóm đã đạt được các kết quả cụ thể sau:

- **Về mặt lý thuyết:** Nhóm đã hệ thống hóa thành công các kiến thức nền tảng về quy trình của một hệ thống phân tích biểu cảm khuôn mặt tự động (AFEA) truyền thống từ giáo

trình chuyên ngành, đồng thời nghiên cứu chuyên sâu bài báo khoa học SOTA tại hội nghị ECCV 2024 về phương pháp CAFE. Sự đối sánh kỹ thuật chi tiết giữa các đặc trưng thủ công (geometric, appearance features) và đặc trưng học sâu đa phương thức hiện đại đã giúp nhóm làm rõ bước chuyển dịch công nghệ của lĩnh vực nhận dạng mẫu trong kỷ nguyên mô hình nền tảng.

- **Về mặt thực nghiệm:** Nhóm đã tái cài đặt và huấn luyện thành công mô hình CAFE trên tập dữ liệu nguồn RAF-DB, đồng thời thực hiện đánh giá chéo chéo miền (zero-shot cross-domain) trên năm bộ dữ liệu đích bao gồm FERPlus, AffectNet, SFEW2.0, MMAFEDB và bộ dữ liệu mở rộng ngoài bài báo CK+48. Các kết quả thực nghiệm thu được có độ chính xác rất cao, tiệm cận và thậm chí vượt trội hơn so với số liệu được công bố trong bài báo gốc (đạt độ chính xác tổng thể 89.15% trên RAF-DB và 52.01% trên AffectNet), qua đó xác thực mạnh mẽ tính đúng đắn của giả thuyết nghiên cứu.
- **Về mặt ứng dụng:** Nhóm đã phát triển thành công ứng dụng demo nhận dạng cảm xúc thời gian thực qua webcam laptop theo hai hướng tiếp cận song song: sử dụng mô hình CAFE đã huấn luyện và sử dụng mô hình CLIP thuần zero-shot với các prompt văn bản tùy biến. Cả hai ứng dụng đều vận hành ổn định, trực quan hóa sinh động kết quả dự đoán và điểm số tin cậy trực tiếp trên luồng video của người dùng.

Nhìn chung, đồ án này không chỉ giúp các thành viên trong nhóm củng cố vững chắc các kiến thức lý thuyết đã học trên lớp, mà còn rèn luyện kỹ năng giải quyết các bài toán thực tế của học sâu như sự lệch miền dữ liệu (domain gap), chất lượng ảnh thấp và sự mất cân bằng phân phối lớp nghiêm trọng. Những kết quả đạt được và các hướng phát triển được đề xuất trong báo cáo sẽ là nền tảng quan trọng giúp nhóm tiếp tục nghiên cứu sâu hơn về thị giác máy tính và trí tuệ nhân tạo trong tương lai.

Tài liệu

- [1] Emad Barsoum, Cha Zhang, Cristian Canton Ferrer, and Zhengyou Zhang. Training deep networks for facial expression recognition with crowd-sourced labels. In *Proceedings of the 18th ACM International Conference on Multimodal Interaction*, pages 16–20, 2016.
- [2] Abhinav Dhall, Roland Goecke, Simon Lucey, and Tom Gedeon. Acted facial expressions in the wild database. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR) - Workshops*, 2011.
- [3] Anil K Jain, Patrick Flynn, and Arun A Ross. *Handbook of Biometrics*. Springer, 2008.
- [4] Stan Z Li and Anil K Jain. *Handbook of Face Recognition*. Springer, 2nd edition, 2011.
- [5] Patrick Lucey, Jeffrey F Cohn, Takeo Kanade, Jason Saragih, Zara Ambadar, and Iain Matthews. The extended cohn-kanade dataset (ck+): A complete dataset for action unit and emotion-specified expression. In *Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition - Workshops*, pages 94–101, 2010.
- [6] Ali Mollahosseini, Behzad Hasani, and Mohammad H Mahoor. Affectnet: A database for facial expression, valence, and arousal in the wild. *IEEE Transactions on Affective Computing*, 10(1):18–31, 2017.
- [7] Mahmoud Souri. Mma facial expression database, 2021.
- [8] Yuhang Zhang, Xiuqi Zheng, Chenyi Liang, Jiani Hu, and Weihong Deng. Generalizable facial expression recognition. In *European Conference on Computer Vision (ECCV)*, 2024.